基于机器学习方法的水库滑坡位移预测及预警研究——以藕塘滑坡为例

韦承谦

2026 年 3 月 27 日

目录

一 绪论 **3**
1.1 研究意义和目的 3
1.1.1 理论意义 3
1.1.2 现实意义 3
1.1.3 目的 4
1.2 滑坡位移预测研究现状（国内外研究现状） 4
1.3 滑坡预警研究现状 4
1.4 主要研究内容及技术路线 4

二 基于机器学习的水库滑坡时空位移预测及预警研究 **4**
2.1 前言 4
2.2 工程概况 4
2.3 研究方法 5
2.3.1 算法流程 5
2.3.2 可解释机器学习模型 5
2.3.3 候选特征选择 9
2.3.4 藕塘滑坡变形机制分析 9
2.4 结果及讨论 10
2.4.1 数据准备与模型构建 10
2.4.2 模型性能评估 11
2.4.3 SHAP 可解释性分析 12
2.4.4 讨论 14
2.5 本章小结 15

三 基于位移运动学特征的滑坡位移预测模型研究 **16**
3.1 前言 16
3.2 方法原理 17
3.2.1 长短期记忆网络（LSTM） 17
3.2.2 门控循环单元（GRU） 18
3.2.3 基于多次运行的概率预测 19
3.2.4 模型评价指标 20
3.3 实验结果与分析 21
3.3.1 数据准备与预处理 21
3.3.2 网络结构和超参数设置 22
3.3.3 LSTM 预测结果 22
3.3.4 GRU 预测结果 22
3.3.5 LSTM 与 GRU 对比分析 23
3.4 本章小结 25

一　绪论

1.1　研究意义和目的

1.1.1　理论意义

本研究针对大型水库滑坡内部变形空间不均匀及多场耦合机制复杂的科学难题，旨在突破传统单点位移预测模型割裂滑坡体时空联系的局限性。三峡库区特大型滑坡（如藕塘滑坡）通常具有显著的分区、分级变形特征，传统的时间序列分析方法往往难以揭示滑坡后缘推力与前缘阻滑效应之间的力学传递规律。本课题通过构建基于时空图神经网络的预测架构，将滑坡视为一个有机互馈的动力学系统，有助于从数据驱动的视角厘清滑坡不同块体间的协同演化机制与链式响应规律，为完善复杂岩土介质的非线性动力学理论提供新的切入点。此外，针对深度学习模型普遍存在的”黑箱”问题，本研究引入注意力机制与特征归因分析方法，致力于定量解析库水位涨落与降雨入渗对滑坡位移的”滞后衰减效应”及贡献权重。这种尝试不仅赋予了机器学习模型以明确的物理可解释性，也为揭示”水-土”相互作用下阶跃型滑坡的成因机理提供了可量化的数据支撑，实现了从纯粹的数据挖掘向地质机理反演的理论跨越。

1.1.2　现实意义

本课题的研究成果对于提升三峡库区重大地质灾害的防灾减灾水平具有重要的应用价值。藕塘滑坡作为三峡库区体积巨大、变形机制复杂的典型涉水滑坡，其稳定性直接关系到长江黄金水道的通航安全及库区沿岸居民的生命财产安全。本研究构建的高精度时空位移预测模型，旨在解决传统方法在极端水文气象工况（如库水位急剧下降叠加持续强降雨）下预测精度失效的难题，力争实现对滑坡灾变趋势的亚毫米级精准把控。更为关键的是，本研究不再满足于单一的位移数值预报，而是建立基于置信区间的动态概率预警体系。这将为地质灾害防治部门提供包含风险概率的科学决策依据，有效降低因监测噪声或局部扰动导致的误报率与漏报率。通过显著延长有效预警的时间窗口，本研究可为制定库水位应急调度方案、实施航道交通管制以及组织人员避险转移争取宝贵的”黄金时间”，从而最大限度地降低潜在的灾害风险与社会经济损失。

1.1.3 目的

1.2 滑坡位移预测研究现状（国内外研究现状）

1.3 滑坡预警研究现状

1.4 主要研究内容及技术路线

二 基于机器学习的水库滑坡时空位移预测及预警研究

2.1 前言

在构建数据驱动的水库滑坡时空位移预测模型时，输入特征的科学选取直接决定了模型的预测精度与泛化能力。传统基于经验的特征选择方法虽具备一定的工程地质学基础，但在处理复杂非线性的监测数据时往往带有较强的主观性，难以定量刻画各诱发因素的具体影响程度，缺乏统一的标准。为此，本章引入高效的梯度提升框架（LightGBM）与可解释性机器学习工具（SHAP），旨在对滑坡变形的候选驱动因子进行精准的定量评估与优选。本研究以典型的藕塘滑坡为案例，针对其复杂的地质演化特征，收集并整理了该区域长时间序列的库水位、降雨量及地表时空位移等监测数据。基于 LightGBM 模型的高效拟合能力，结合 SHAP 方法深入剖析各输入特征对滑坡时空位移的贡献度。通过特征重要性图、局部依赖图和特征交互效应图等多维度的可视化分析，系统揭示水文气象因素与滑坡变形之间的内在非线性映射关系。本章采用”先验知识指导初筛 + 数据算法量化验证”的研究策略，不仅有效克服了传统机器学习模型”黑盒”特性的不足，提升了特征选择的科学性与物理可解释性，更为后续构建高精度的藕塘滑坡时空位移预测及预警模型奠定了坚实的数据基础与理论支撑。

2.2 工程概况

本研究以典型的阶跃型水库滑坡——藕塘滑坡为核心研究对象。藕塘滑坡位于三峡库区重庆市奉节县安坪镇的长江南岸，属于构造剥蚀的中低山河谷地貌。该区域地形总体呈南高北低之势，滑坡体后缘高程达 700 余米，前缘直抵长江干流，整体坡度多在 15° 至 30° 之间。研究区出露地层主要以侏罗系（J）的泥岩、砂质泥岩与粉砂岩互层为主，这种软硬相间的岩层结构在长期风化和水流侵蚀下，极易形成软弱滑动面。

在气候与水文条件方面，该地区属于亚热带季风气候，年平均气温约为 18°C，多年平均降水量在 1100 毫米左右。降水在年内分配极不均匀，主要集中在每年的 5 月至 9 月，且多以暴雨形式出现。此外，三峡水库的周期性调度对滑坡的稳定性影响显著。库水位每年在 145 米至 175 米之间进行季节性的大幅波动：通常于 9 月开始蓄水，年末达到并维持 175 米高水位，次年春季逐步消落至 145 米防洪限制水位。

研究区域的地下水动态受大气降水和水库蓄水双重控制。频繁的库水位升降交

替与季节性强降雨的耦合作用，不断改变着坡体的渗流场与应力状态。鉴于藕塘滑坡体量巨大、地质条件复杂且变形响应极其敏感，将其作为此时空位移预测及预警模型研究的案例，具有重要的科学意义与防灾减灾实践价值。

2.3 研究方法

在明确了滑坡变形的潜在触发因子后，本文采用 LightGBM 模型探索藕塘滑坡时空位移变形与降雨、库水位、地下水位及温度等相关特征之间的关系。为了进一步提高模型的透明度和可解释性，本文结合 SHAP 方法对 LightGBM 模型进行了解释。通过对历史监测数据的分析，识别出可能导致滑坡变形的关键因素，其主要流程如下：

首先，在藕塘滑坡区域选择具有代表性的位移监测点（MJ9、MJ1、MJ3），获取长期监测数据。同时根据降雨、库水位、地下水位及气象条件选择相关的触发因子。本研究基于触发因子和监测点的位移数据训练 LightGBM 模型，并利用 SHAP 方法对模型进行解释。

在 LightGBM 模型训练阶段，结合滑坡体的地质背景与已知变形规律，初步筛选具有物理意义的特征因子，通过 SHAP 方法进一步挖掘其对模型预测的贡献与影响形式。通过 SHAP 贡献图、依赖图和交互图，分析不同因子对模型预测结果的贡献，包括：

1. 贡献图分析：各触发因子对 LightGBM 模型位移预测的贡献大小；
2. 依赖图分析：单个触发因子的取值变化如何影响模型的位移预测；
3. 交互图分析：两个触发因子交互时，不同特征值组合对位移预测的影响。

通过上述”LightGBM+SHAP” 方法的分析与解释，本研究从定量层面揭示了各触发因子的独立贡献、滑坡对不同触发因子变化的非线性响应和对触发因子之间的非线性耦合机制的响应，为后续滑坡时空位移预测及预警建模提供支持。

2.3.1 算法流程

本研究的技术路线如图 2-1所示，主要包括数据采集、模型训练、可解释性分析三个核心环节。

2.3.2 可解释机器学习模型

LightGBM 模型 LightGBM 是一种高效的梯度提升树（GBDT）框架，广泛应用于大规模机器学习任务，尤其是在数据量大且高维度特征的情况下。LightGBM 通过对传统梯度提升树（GBDT）算法进行优化，提供了更高的计算效率、内存消耗更低，同时具有较强的泛化能力，适用于分类、回归、排序等多种任务。LightGBM 的核心思想与传统的梯度提升方法相同，都是通过集成多个决策树来提升模型的预测性能。

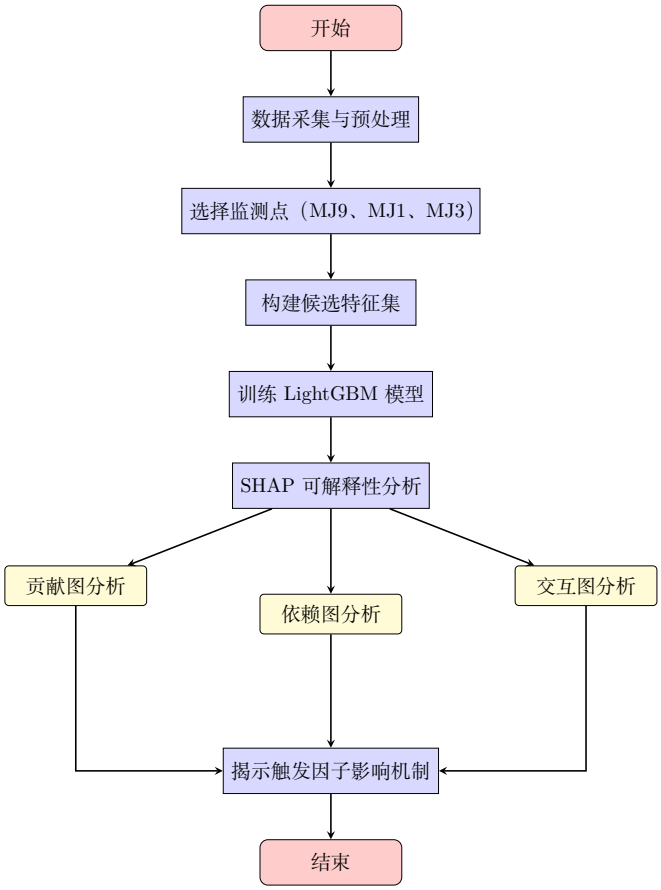

图 2-1: 基于 LightGBM+SHAP 的滑坡位移预测算法流程图

通过不断添加新的树来拟合误差，并结合多个树的输出，生成最终的预测结果。但 LightGBM 在此基础上做了一些重要的优化，使得它能够更高效地处理大规模数据集。

LightGBM 在梯度提升树的基础上，采用了以下关键技术：

1. **直方图算法**：通过将连续特征值离散化为多个区间，在构建树时使用这些区间来选择分裂点，从而减少了计算量并提高了训练效率。特别是在处理高维数据时，直方图算法表现出显著的优势。

2. **叶子生长策略**：传统的 GBDT 采用层级生长策略，即在每一层分裂中分配节点，而 LightGBM 采用叶子生长策略。在这种策略中，LightGBM 优先选择误差最小的叶子进行分裂，从而使得每棵树能够更好地拟合数据，尤其是在训练数据集不平衡时。

3. **基于梯度的单边抽样（GOSS）**：GOSS 技术通过在训练过程中丢弃低梯度的样本，只保留高梯度样本来进行计算。这样可以保留最有信息的样本，提高模型训练的效率。

4. **互斥特征捆绑（EFB）**：EFB 技术将互斥的特征捆绑在一起，从而减少了特征数量，避免了高维特征带来的计算开销。该方法对于稀疏数据集尤为有效。

LightGBM 通过引入直方图算法、叶子生长策略、GOSS 和 EFB 等优化方法，显著提高了梯度提升树在大规模数据集上的训练速度和计算效率。其对类别特征的原生支持、低内存消耗以及并行计算能力，使其在许多实际应用中成为首选的机器学习工具。通过调节超参数和特征选择，LightGBM 能够在不同任务中提供优异的性能。

其 LightGBM 将决策树作为基学习器，表示为：

$$F = \{F_1, F_2, \ldots, F_n\} \tag{1}$$

式中，F_i 表示第 i 个学习器，F 表示所有学习器的集合。

LightGBM 通过多次的迭代不断地提升学习器的性能，每次迭代是为获得一个弱学习器，使迭代损失函数 $L(y, F_t(x))$ 最小，其公式为：

$$F_t(x) = F_{t-1}(x) + f_t(x) \tag{2}$$

式中，$F_{t-1}(x)$、$L(y, F_{t-1}(x))$ 分别为上一次迭代获得的强学习器和损失函数。

计算损失函数的负梯度用于拟合本次迭代损失近似值，其公式为：

$$r_{ti} = -\left[\frac{\partial L(y_i, F_{t-1}(x_i))}{\partial F_{t-1}(x_i)}\right] \tag{3}$$

目标函数通常为平方差，使用平方差近似拟合为：

$$f_t(x) = \arg\min \sum_i (r_{ti} - f(x_i))^2 \tag{4}$$

最终获得本次迭代获得的强学习器为：

$$F_t(x) = F_{t-1}(x) + \eta f_t(x) \tag{5}$$

LightGBM 模型通过以上方式不断更新，采用 histogram 算法减少内存的使用和计算的复杂度，使用 Leaf-wise 的叶子优先生长策略，并通过设置最大树深限制其结构复杂度。该方法能够在保证精度的前提下加快收敛速度，相较于传统的 Level-wise 方法更适用于大规模数据场景。基于梯度的单边采样（GOSS）和互斥特征捆绑（EFB）减少训练时间。

SHAP 解释模型 SHAP 是基于博弈论的解释方法，用于解释机器学习模型的预测结果，量化了每个特征对单一预测结果的贡献。SHAP 值为每个特征分配一个值，表示该特征对某一预测结果的贡献度。它是一种非常强大的工具，能够帮助我们理解模型是如何根据输入特征做出预测的，尤其对于复杂的模型（如 LightGBM、XGBoost 等树模型）尤为有效。对于给定的输入样本 x 有着 N 个解释变量，解释模型 g 表示特征贡献的线性函数：

$$g(x') = \varphi_0 + \sum_{j=1}^{N} \varphi_j x'_j \tag{6}$$

式中 φ_0 代表模型输出的基本值，N 是所有输入特征的总数，x'_j 是二元变量，表示第 j 个预测变量是否存在（$x'_j = 1$）或不存在（$x'_j = 0$）。$\varphi_j \in \mathbb{R}$ 是样本 x 中第 j 个的 SHAP 值（即特征属性）。

$$\varphi_j = \sum_{S \subseteq N \setminus \{j\}} \frac{|S|!(N - |S| - 1)!}{N!} [f(S \cup \{j\}) - f(S)] \tag{7}$$

其中，S 表示输入的解释变量的子集，$f(S \cup \{j\})$ 和 $f(S)$ 分别是包含和不包含第 j 个特征时模型的预测值。

$$\varphi_{j,k} = \sum_{S \subseteq N \setminus \{j,k\}} \frac{|S|!(N - |S| - 2)!}{2(N-1)!} \nabla_{jk}(S) \tag{8}$$

此外，为了量化变量之间的配对相互影响，SHAP 交互值被引入用于度量特征之间的交互影响。

$$\nabla_{jk}(S) = f_x(S \cup x_j, x_k) - f_x(S \cup x_j) - f_x(S \cup x_k) + f_x(S) \tag{9}$$

当 $j \neq k$ 时，由于特征 j 和 k 之间的 SHAP 交互值平均分配到 $\varphi_{j,k}$ 和 $\varphi_{k,j}$ 中，因此总的交互影响是 $\varphi_{j,k}$ 和 $\varphi_{k,j}$ 的和。每个变量的主要影响是通过从 SHAP 值中减去 SHAP 交互值来确定的。

2.3.3 候选特征选择

滑坡的候选因素应结合物理机理与数据驱动分析两方面进行综合选取。从物理机制角度来看，滑坡的发生和发展过程通常受多种自然环境与工程活动因素的共同作用，这些因素会影响坡体的应力状态、地下水变化和土体结构稳定性。特别是库水位变化和强降雨事件，常常是诱发滑坡活动的直接触发因素。坡度、地层岩性、软弱结构面等内在地质条件，则决定了滑坡的易发性与演化路径。

在本次的初始特征选择中，参考了前人的研究成果，针对藕塘滑坡的时空位移预测任务，初步筛选出基于时间窗口的滞后特征，包括历史位移、降雨、库水位、地下水位及气象因子，如表2-1所示。

表 2-1: 触发特征的候选因子

候选因素类别	描述
历史位移特征	过去 5 天的位移值 disp$(t-5)$ 至 disp$(t-1)$
降雨特征	过去 5 天的日降雨量 Rainfall$(t-5)$ 至 Rainfall$(t-1)$ [mm]
库水位特征	过去 5 天的库水位 RWL$(t-5)$ 至 RWL$(t-1)$ [m]
地下水位特征	过去 5 天的地下水位 GWT$(t-5)$ 至 GWT$(t-1)$ [m]
平均温度特征	过去 5 天的平均温度 aveT$(t-5)$ 至 aveT$(t-1)$ [°C]
最低温度特征	过去 5 天的最低温度 minT$(t-5)$ 至 minT$(t-1)$ [°C]
最高温度特征	过去 5 天的最高温度 maxT$(t-5)$ 至 maxT$(t-1)$ [°C]
露点特征	过去 5 天的露点 DP$(t-5)$ 至 DP$(t-1)$ [°C]
相对湿度特征	过去 5 天的相对湿度 RH$(t-5)$ 至 RH$(t-1)$ [%]
监测点标识	监测点 one-hot 编码（MJ9、MJ1、MJ3）

2.3.4 藕塘滑坡变形机制分析

藕塘滑坡作为三峡库区典型的水库型滑坡，其位移过程表现出明显的阶跃特征，即在特定时间段内位移突增，而在其他时间段相对稳定。这类位移特征在库区滑坡中具有代表性，通常受到周期性库水位变化和突发性降雨过程的共同驱动。藕塘滑坡地质背景复杂，主要分布于软弱堆积层或顺层结构发育的坡体中，地层结构和物理力学性质使其对外部水动力扰动极为敏感。此外，其所处区域的库水位调控方式及年降雨量水平也具有典型性。因此，在地质构造、水文气象条件相近的背景下，藕塘滑坡呈现出独特的变形响应特征。为深入理解三峡库区滑坡位移的形成与演化规律，有必要进一步分析其滑坡变形机制，揭示库水位与降雨在不同阶段如何共同作用于滑坡体，驱动滑坡变形及失稳过程。

从三峡库区典型滑坡的变形演化过程来看，滑坡体的阶跃式位移通常源于降雨和库水位变化的耦合作用机制。这一机制主要通过以下几种路径对滑坡变形产生影响：

1. **库水位变化引起的软化与卸载作用**：在水库蓄水或调控过程中，库水位的周期性涨落会引发滑坡体前缘的软化和卸载效应。当库水位快速下降时，坡脚支撑力减弱，滑坡体前缘土体失去约束，同时滑坡体内部由于仍处于高孔隙水压力状态，造成剪切应力增大，滑坡体发生应力重分布，进而引发滑动。特别是对于具有顺层结构或软弱夹层的滑坡体，该过程更加显著。

2. **降雨入渗引起的孔隙水压力升高**：持续或强降雨会导致雨水大量入渗，改变滑坡体内部的水文条件。随着入渗深度的增加，孔隙水压力迅速上升，有效应力降低，滑动面抗剪强度减弱，从而诱发滑坡位移。此外，强降雨还可能造成坡面径流侵蚀或沟蚀作用，削弱滑坡体的表层稳定性，加速变形。

3. **库水位与降雨的协同效应**：研究发现，单一因素（仅降雨或仅水位变化）难以充分解释大部分滑坡的突跳式位移行为，而库水位下降与强降雨同时发生时，往往引发滑坡的突发性变形。这是由于两种作用机制相互叠加，共同降低滑坡体的稳定性。例如，在库水位下降期遇上强降雨事件，不仅坡体抗剪强度削弱，而且坡脚卸载增强，极易导致大位移的发生。

4. **地质结构条件的调控作用**：上述变形机制的实际表现形式，还受到滑坡体地质构造的影响。藕塘滑坡广泛发育软弱层或顺倾结构带，岩土体抗剪强度低，对水敏感性强，更容易在外部水动力作用下发生变形破坏。同时，滑带土中黏粒含量高、渗透性差，也促进孔压积聚，加剧滑坡体失稳。

综合前人研究成果可知，藕塘滑坡的变形机理主要体现在以下几个方面：

1. 库水位变化是滑坡变形的核心驱动因素，其中尤以水位快速下降引发的动水压力变化对滑坡体稳定性的影响最为显著；

2. 降雨通过增加孔隙水压力、软化岩土体等作用机制，与库水位变化产生叠加效应，进一步加剧滑坡变形过程；

3. 滑坡体渗透性的差异性也决定了其对水位变化的响应程度，渗透性较差的滑坡在水位骤降时更易出现失稳滑动现象。

2.4 结果及讨论

2.4.1 数据准备与模型构建

本研究基于藕塘滑坡区域的长期监测数据，选取了三个具有代表性的位移监测点（MJ9、MJ1、MJ3）进行分析。监测数据时间跨度覆盖了多个完整的库水位调度周期，包含了丰富的滑坡变形信息。数据集包括日尺度的位移监测值、降雨量、库水位、地下水位以及气象要素（平均温度、最低温度、最高温度、露点、相对湿度）等多维度信息。

在样本构造阶段，采用时间窗口为 5 天的滑动窗口方法，将历史时序数据转化为监督学习样本。对于每个监测点，输入特征包括：该点过去 5 天的位移值、过去 5 天的环境因子（降雨、库水位、地下水位、温度、湿度等）以及监测点的 one-hot 编码。回归任务的目标变量为当天的位移增量（$\Delta u = u_t - u_{t-1}$），用于预测滑坡的时空位移变化；分类任务的目标变量基于位移增量是否超过固定阈值 0.3 mm 来定义，用于判定是否进入预警状态。为了严格防止模型评估中出现隐性的数据泄漏，本研究仅基于训练集的统计分布特征来划定预警阈值。通过对训练集数据的统计分析，设定 0.3 mm 为分类任务的固定阈值。该数值接近 MJ9 监测点训练集的 95% 分位数，同时处于 MJ1 和 MJ3 监测点训练集的 75% 至 90% 分位数之间。这一基于先验训练数据的固定阈值设定，不仅有效捕捉了异常变形信号，还避免了在时序交叉验证中使用全局统计量带来的未来数据泄漏风险，确保了模型评估的严谨性与客观性。

在模型验证策略上，本研究采用 5 折时序交叉验证（TimeSeriesSplit）对模型性能进行评估。时序交叉验证严格保持数据的时间顺序，每一折中训练集始终位于测试集之前，从而避免了随机划分可能导致的”未来数据泄漏”问题，真实模拟了实际预测场景中的时序依赖关系。针对预警样本在时间维度上分布不均匀的问题（预警事件往往集中在特定时期），本研究在每一折的训练阶段引入 SMOTE（Synthetic Minority Over-sampling Technique）过采样技术，仅对训练集中的少数类样本进行合成扩充，以缓解类别不平衡对分类模型学习的影响。需要强调的是，SMOTE 操作严格限定在训练集内部，测试集保持原始分布不变，确保评估结果的客观性。由于 LightGBM 是基于树的模型，对特征尺度不敏感，因此无需进行标准化处理。

2.4.2 模型性能评估

时空位移预测模型（回归任务） 基于 LightGBM 构建的回归模型用于预测藕塘滑坡的时空位移增量。模型采用了较为保守的超参数设置，包括较小的树深度（max_depth=3）和叶子节点数（num_leaves=4），以及适度的正则化参数（lambda_l1=0.2, lambda_l2=0.2），以防止过拟合并提高模型的泛化能力。同时设置特征采样比例（feature_fraction=0.8）和样本采样比例（bagging_fraction=0.8），进一步增强模型的鲁棒性。

经 5 折时序交叉验证，回归模型在训练集和测试集上的均方误差（MSE）分别为 0.0466 ± 0.0492 和 0.0780 ± 0.0641。测试集上的 MSE 表明模型具有一定的预测精度，能够捕捉滑坡位移增量的变化趋势。训练集与测试集误差的差异反映了时序预测任务的固有难度——由于预警事件在时间维度上分布不均匀，不同时期的位移增量变化幅度存在较大差异，导致各折之间的标准差较大。总体而言，模型在严格的时序验证框架下展现出合理的泛化性能。

预警判定模型（分类任务） 基于 LightGBM 构建的分类模型用于判定滑坡是否进入预警状态。模型采用了二分类目标函数，并综合运用两种类别平衡策略：一是在训练集上使用 SMOTE 过采样技术合成少数类样本，二是设置 scale_pos_weight=5 对正样本赋予更高的损失权重。分类模型采用了 num_leaves=8、max_depth=3 的树结构，以及较强的正则化参数（lambda_l1=0.3, lambda_l2=0.3），在模型复杂度与

泛化能力之间取得平衡。

经 5 折时序交叉验证（其中 2 折因测试集无正样本而跳过），分类模型在有效折上的测试集 AUC 为 0.6795 ± 0.1181，召回率（Recall）为 0.7623 ± 0.3362，精确率（Precision）为 0.2970 ± 0.2476，F1 分数为 0.3935 ± 0.2790。训练集 AUC 为 0.9423 ± 0.0405，表明模型具有较强的学习能力。

从预警系统的实际应用角度分析，模型的召回率达到 76.23%，意味着超过四分之三的真实预警事件能够被模型成功识别，这对于灾害预警系统而言具有重要的实用价值——在滑坡预警场景中，漏报的代价远高于误报。测试集 AUC 的波动（标准差 0.1181）主要源于预警事件在时间维度上的非均匀分布特征，这是时序预测任务的固有挑战。需要指出的是，部分折次因测试时段恰好处于滑坡稳定期而无预警样本，这一现象本身也反映了滑坡变形的阶跃性特征。相比于采用随机打乱的分层交叉验证可能获得的虚高指标，本研究坚持使用严格的时序验证策略，所得结果更能真实反映模型在实际预测场景中的表现。

2.4.3 SHAP 可解释性分析

为了深入理解模型的预测机制，揭示各输入特征对滑坡位移预测的贡献，本研究采用 SHAP 方法对训练好的 LightGBM 模型进行了可解释性分析。具体而言，选取时序交叉验证中最后一折训练得到的模型作为解释对象，该折模型使用了最大规模的训练数据，能够最充分地学习特征与位移之间的映射关系。

回归模型的 SHAP 分析 图2-2展示了回归模型的 SHAP 特征重要性总结图。从图中可以看出，对滑坡位移增量预测贡献最大的特征主要包括：

1. **历史位移特征**：过去 5 天的位移值（特别是 $\mathrm{disp}(t-1)$ 和 $\mathrm{disp}(t-2)$）对当前位移增量的预测具有显著贡献。这符合滑坡变形的时序连续性特征，即近期的位移状态对未来位移具有强烈的指示作用。

2. **库水位特征**：库水位的滞后特征（$\mathrm{RWL}(t-1)$ 至 $\mathrm{RWL}(t-5)$）在模型预测中占据重要地位。SHAP 值的分布显示，库水位的变化对滑坡位移具有复杂的非线性影响。当库水位较低或快速下降时，SHAP 值倾向于正值，表明这些条件会促进位移增量的增大；而当库水位较高且稳定时，SHAP 值倾向于负值，表明滑坡处于相对稳定状态。

3. **降雨特征**：降雨量的滞后特征（$\mathrm{Rainfall}(t-1)$ 至 $\mathrm{Rainfall}(t-5)$）也显示出明显的贡献。较大的降雨量对应较高的正向 SHAP 值，表明强降雨会显著增加滑坡位移增量。这与降雨入渗导致孔隙水压力升高、有效应力降低的物理机制相吻合。

4. **地下水位特征**：地下水位（GWT）的变化对滑坡位移也有重要影响。地下水位的升高通常对应正向 SHAP 值，表明地下水位上升会增加滑坡变形的风险。

5. **气象特征**：温度、露点、相对湿度等气象特征虽然贡献相对较小，但仍在模型中发挥作用。这些特征可能通过影响土体的冻融循环、蒸发蒸腾等过程，间接影响滑坡的稳定性。

6. **监测点标识**：不同监测点的 one-hot 编码特征也显示出一定的贡献，表明不同位置的监测点对外部触发因素的响应存在差异，这与滑坡体内部的地质结构异质性有关。

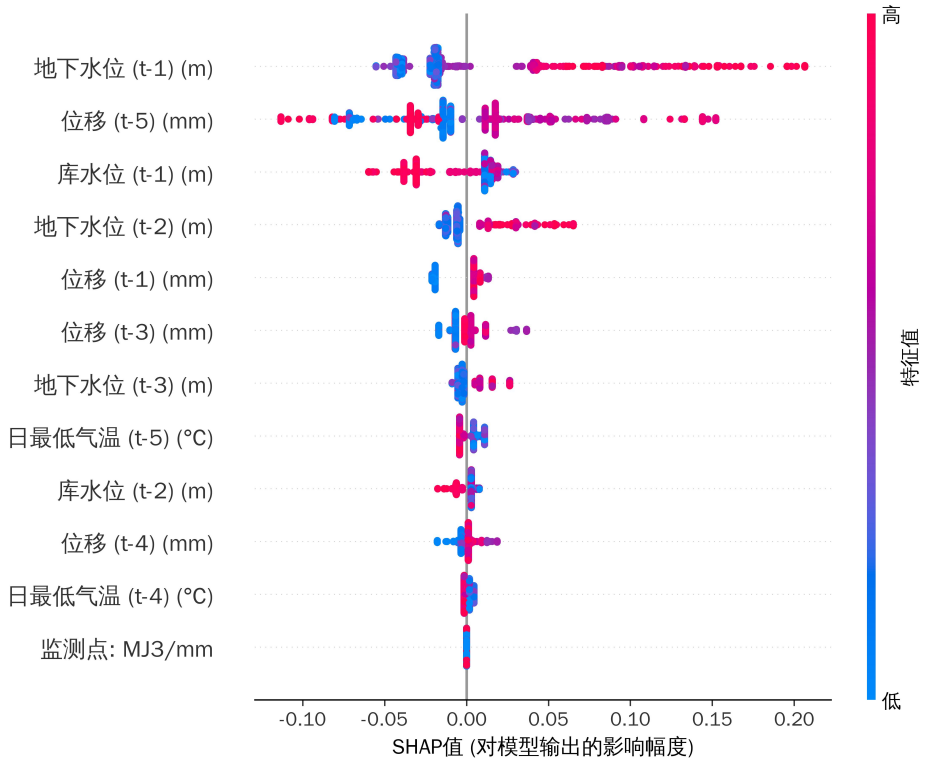

图 2-2: SHAP 特征重要性总结图（回归模型）

分类模型的 SHAP 分析　图2-3展示了分类模型的 SHAP 特征重要性总结图（针对预警状态）。从图中可以看出，促使滑坡进入预警状态的关键因子包括：

1. **历史位移特征**：与回归模型类似，近期的位移值（特别是 $\mathrm{disp}(t-1)$）对预警判定具有最强的指示作用。较大的历史位移值对应较高的正向 SHAP 值，表明滑坡已经处于活跃变形状态，进入预警的概率显著增加。

2. **库水位特征**：库水位的快速下降是触发预警的重要因素。SHAP 分析显示，当库水位处于较低水平或短期内大幅下降时，模型倾向于判定为预警状态。这与库水位下降引起的坡脚卸载和动水压力变化机制相一致。

3. **降雨特征**：强降雨事件是触发预警的另一关键因素。当短期内累积降雨量较大时（特别是 $\mathrm{Rainfall}(t-1)$ 和 $\mathrm{Rainfall}(t-2)$），SHAP 值显著增大，表明模型识别到了降雨诱发滑坡变形的风险。

4. **地下水位特征**：地下水位的快速上升也是预警的重要指标。这反映了降雨入渗和库水位变化对地下水动态的综合影响。

5. **特征交互效应**：分类模型的 SHAP 分析还揭示了特征之间的交互效应。例如，当库水位下降与强降雨同时发生时，两者的协同作用会显著增加进入预警状态的概率，这与前述的耦合作用机制相吻合。

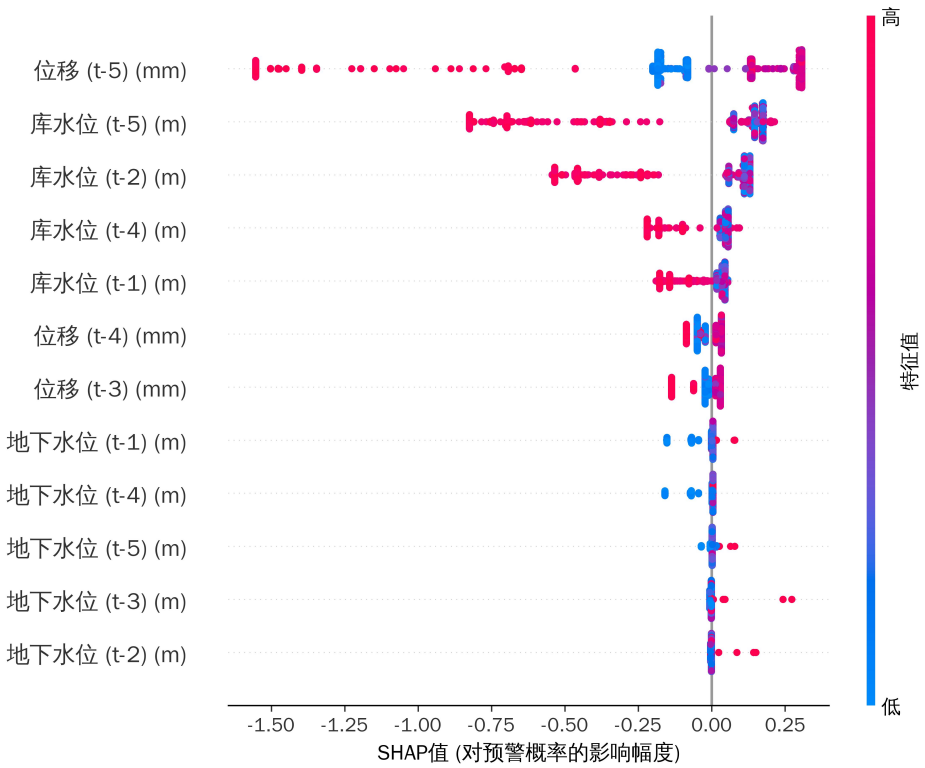

图 2-3: SHAP 特征重要性总结图（分类模型）

2.4.4 讨论

特征重要性与物理机制的一致性 SHAP 分析结果与藕塘滑坡的物理变形机制高度一致。库水位变化和降雨量作为最重要的触发因子，在 SHAP 贡献图中占据主导地位，这验证了”库水位-降雨耦合驱动”的变形机制假设。历史位移特征的高重要性则反映了滑坡变形的时序连续性和累积效应。地下水位作为连接外部触发因素（降雨、库水位）与滑坡内部响应的桥梁，其重要性也得到了 SHAP 分析的支持。

非线性响应特征 SHAP 依赖图揭示了滑坡对触发因素的非线性响应。例如，库水位对滑坡位移的影响并非简单的线性关系，而是存在阈值效应：当库水位低于某一临界值或下降速率超过某一阈值时，滑坡变形会显著加剧。类似地，降雨量也存在触发阈值，只有当累积降雨量超过一定值时，才会对滑坡位移产生显著影响。

时空差异性 不同监测点的 one-hot 编码特征在 SHAP 分析中显示出一定的贡献，表明滑坡体内部存在时空差异性。这种差异性可能源于：(1) 不同位置的地质结构差异（如滑带厚度、岩土体性质）；(2) 不同位置对外部触发因素的响应敏感性差异；(3) 不同位置的排水条件和渗流路径差异。这一发现强调了在滑坡预测和预警中考虑空间异质性的重要性。

预警模型的实用价值 分类模型的 SHAP 分析为滑坡预警系统的构建提供了明确的指导。通过识别促使进入预警状态的关键因子及其阈值，可以建立基于多因子联合判定的预警准则。例如，当历史位移增量较大、库水位快速下降且遭遇强降雨时，应立即发布预警信号。模型在严格时序验证下的召回率达到 76.23%，表明超过四分之三的真实预警事件能够被成功捕捉，这对于”宁可误报、不可漏报”的灾害预警原则具有重要意义。这种基于可解释机器学习的预警方法，相比传统的经验阈值法，具有更强的科学性和可靠性。

模型的局限性与改进方向 尽管本研究构建的 LightGBM 模型在藕塘滑坡的时空位移预测和预警判定中展现出一定的预测能力，但仍存在以下局限性：(1) 时序交叉验证中，由于预警事件在时间维度上的非均匀分布，部分折次的测试集缺乏正样本，导致有效评估折数减少，模型性能指标的波动较大；(2) 模型基于历史数据训练，对于超出训练集范围的极端事件（如特大暴雨、异常库水位调度）的预测能力有待验证；(3) 模型未考虑滑坡体的物理力学参数（如抗剪强度、渗透系数）的时变性；(4) 模型的时间窗口（5 天）是基于经验选择的，可能不是最优值。未来研究可以考虑：(1) 引入物理模型与数据驱动模型的耦合，提高模型的物理可解释性和外推能力；(2) 采用自适应时间窗口或多尺度时间窗口，以更好地捕捉不同时间尺度的变形特征；(3) 结合深度学习方法（如 LSTM、Transformer）进一步提升模型对长期依赖关系的建模能力；(4) 探索更精细的时序划分策略，如滑动窗口验证或基于变形阶段的分段验证，以提高模型评估的稳定性。

2.5 本章小结

本章基于 LightGBM 模型，探讨了藕塘滑坡的时空位移与降雨、库水位、地下水位及气象因子等关键影响因子之间的关系，并采用 SHAP 方法对模型进行可解释性分析。研究从 SHAP 特征贡献、单个影响因子对模型预测的影响及影响因子之间的交互关系三个方面展开，系统揭示了影响因子的重要性排序、单一特征的影响模式以及影响因子间的协同效应，为滑坡时空位移的精准预测和预警提供了科学依据。主要结论如下：

1. 构建了基于 LightGBM 的藕塘滑坡时空位移预测模型和预警判定模型，并采用严格的 5 折时序交叉验证结合 SMOTE 过采样技术进行模型评估。回归模型在测试集上的 MSE 为 0.0780 ± 0.0641，能够有效预测滑坡的位移增量；分类模型在测试集上的 AUC 为 0.6795 ± 0.1181，召回率达到 76.23%，能够识别大部分

真实预警事件。时序验证策略严格避免了数据泄漏，所得结果真实反映了模型在实际预测场景中的性能，为滑坡监测预警系统的构建提供了可靠的技术支撑。

2. SHAP 贡献图识别了影响滑坡位移预测的核心特征，直观展示了不同触发因子的特征值对模型预测的影响。对于藕塘滑坡，影响位移预测最大的特征包括：历史位移值（disp($t-1$) 至 disp($t-5$)）、库水位（RWL($t-1$) 至 RWL($t-5$)）、降雨量（Rainfall($t-1$) 至 Rainfall($t-5$)）以及地下水位（GWT($t-1$) 至 GWT($t-5$)）。这些主控因子与阶跃型滑坡的变形机理基本吻合，验证了”库水位-降雨耦合驱动”的变形机制假设。

3. SHAP 依赖图进一步揭示了单个影响因子对预测结果的具体影响模式，展现了特征值变化对滑坡位移的非线性作用及潜在的阈值效应。研究发现，库水位较低或快速下降、降雨量超过特定阈值、地下水位快速上升等条件会显著加剧滑坡位移的发生。这些发现为建立基于多因子联合判定的预警准则提供了定量依据。

4. SHAP 交互图揭示了不同特征之间的相互作用，分析了特定特征在不同条件下对滑坡位移的增强或削弱效应，为深入理解滑坡演化机理提供了新视角。对于藕塘滑坡，降雨与库水位的联合作用中，当库水位下降与强降雨同时发生时，两者的协同效应会显著增加滑坡进入预警状态的概率。

5. 本章采用的”LightGBM+SHAP”方法有效克服了传统机器学习模型”黑盒”特性的不足，提升了特征选择的科学性与模型的可解释性。在模型验证方面，采用严格的时序交叉验证策略并结合 SMOTE 过采样技术处理类别不平衡问题，确保了评估结果的学术严谨性和实际可信度。通过”先验知识指导初筛 + 数据算法量化验证”的研究策略，不仅实现了对候选因子的精准筛选与排序，更为后续滑坡时空位移预测及预警模型的优化提供了数据支持和理论依据。

本章的研究成果为三峡库区及类似地质环境下的滑坡监测预警提供了可借鉴的技术路线和方法体系，具有重要的科学意义和工程应用价值。

三　基于位移运动学特征的滑坡位移预测模型研究

3.1　前言

在第二章中，本研究通过 LightGBM 模型结合 SHAP 方法，系统地识别并量化了影响藕塘滑坡位移变形的关键触发因子，包括降雨、库水位、地下水位及气象因素等。这些特征的筛选为本章的位移预测奠定了特征基础。然而，第二章的工作主要聚焦于特征重要性分析，尚未构建位移预测模型。

水库滑坡的位移演化过程具有复杂的非线性时变特性。在库水位变化和降雨等外部触发因素作用下，滑坡体会产生突发性的位移增量，而在其他时段则相对稳定。

这种复杂的时序特征使得传统线性模型难以准确刻画滑坡的变形规律，需要能够捕捉长期依赖关系的时序预测模型。

为此，本章引入 LSTM 和 GRU 两种主流循环神经网络。LSTM 通过门控机制捕捉长期依赖，适合复杂时序预测；GRU 是 LSTM 的简化版本，参数更少，训练更快。通过对比验证两种模型的性能，评估模型复杂度与预测精度的权衡。

此外，传统点预测无法量化不确定性，在工程应用中存在局限性。为了提供更全面的预测信息，本章采用 50 次运行集成方法构建概率预测框架。对同一模型进行 50 次独立训练，每次使用不同的随机种子初始化参数，收集 50 次预测结果形成统计分布。该方法不仅能够输出位移的期望值，还能同时给出不同置信水平下的预测区间，为滑坡灾害的风险评估与预警决策提供更加全面的信息支持。

本章以藕塘滑坡 MJ9 监测点为研究对象，聚焦单监测点位移预测，验证所提方法的有效性与可靠性，为后续章节的空间预测和预警研究奠定基础。

3.2 方法原理

本章提出的 LSTM/GRU 概率预测模型主要包括两个核心模块：循环神经网络时序预测模块和概率预测模块。模型直接建立触发因子到累积位移的映射关系，不进行位移分解。将第二章筛选出的重要触发因子（降雨、库水位、地下水位等）作为输入，分别构建 LSTM 和 GRU 时序预测模型，直接预测未来时刻的累积位移；通过 50 次独立运行获得预测的统计分布，输出不同置信水平下的预测区间，实现位移的概率预测。

3.2.1 长短期记忆网络（LSTM）

长短期记忆网络（Long Short-Term Memory, LSTM）是一种特殊的循环神经网络（RNN），由 Hochreiter 和 Schmidhuber 于 1997 年提出，专门用于解决传统 RNN 在处理长序列时存在的梯度消失和梯度爆炸问题。LSTM 通过引入门控机制（遗忘门、输入门和输出门）以及记忆单元，能够有效捕捉时间序列数据中的长期依赖关系，特别适用于滑坡位移这类具有复杂时序特征的非线性预测问题。

LSTM 的核心结构包括三个门控单元和一个记忆单元。在时刻 t，LSTM 单元接收当前输入 $\mathbf{x}_t$ 和上一时刻的隐藏状态 $\mathbf{h}_{t-1}$，通过以下计算过程更新记忆单元 $\mathbf{C}_t$ 和输出隐藏状态 $\mathbf{h}_t$：

（1）遗忘门（Forget Gate）：决定从记忆单元中丢弃哪些信息

$$\mathbf{f}_t = \sigma(\mathbf{W}_f \cdot [\mathbf{h}_{t-1}, \mathbf{x}_t] + \mathbf{b}_f) \tag{10}$$

（2）输入门（Input Gate）：决定将哪些新信息存储到记忆单元中

$$\mathbf{i}_t = \sigma(\mathbf{W}_i \cdot [\mathbf{h}_{t-1}, \mathbf{x}_t] + \mathbf{b}_i) \tag{11}$$

$$\tilde{\mathbf{C}}_t = \tanh(\mathbf{W}_C \cdot [\mathbf{h}_{t-1}, \mathbf{x}_t] + \mathbf{b}_C) \tag{12}$$

（3）记忆单元更新：结合遗忘门和输入门的输出更新记忆单元

$$\mathbf{C}_t = \mathbf{f}_t \odot \mathbf{C}_{t-1} + \mathbf{i}_t \odot \tilde{\mathbf{C}}_t \tag{13}$$

（4）输出门（Output Gate）：决定输出哪些信息

$$\mathbf{o}_t = \sigma(\mathbf{W}_o \cdot [\mathbf{h}_{t-1}, \mathbf{x}_t] + \mathbf{b}_o) \tag{14}$$

$$\mathbf{h}_t = \mathbf{o}_t \odot \tanh(\mathbf{C}_t) \tag{15}$$

其中，σ 为 Sigmoid 激活函数，tanh 为双曲正切激活函数，$\odot$ 表示逐元素乘法，$\mathbf{W}$ 和 $\mathbf{b}$ 分别为权重矩阵和偏置向量。

在本研究中，LSTM 模型的输入特征包括第二章通过 SHAP 方法筛选出的重要触发因子（降雨量、库水位、地下水位、平均温度、最低温度、最高温度、露点、相对湿度）的历史序列。模型的输出为未来时刻的累积位移预测值。通过多层 LSTM 结构的堆叠，模型能够学习更加复杂的时序特征表示，从而提高预测精度。

3.2.2 门控循环单元（GRU）

门控循环单元（Gated Recurrent Unit, GRU）是由 Cho 等人于 2014 年提出的一种简化的循环神经网络结构，可以看作是 LSTM 的变体。GRU 通过合并 LSTM 中的遗忘门和输入门为单一的更新门，并将记忆单元和隐藏状态合并，从而减少了模型参数数量，提高了训练效率。尽管结构更简单，GRU 在许多序列建模任务中表现出与 LSTM 相当甚至更优的性能。

GRU 的核心结构包括两个门控单元：更新门和重置门。在时刻 t，GRU 单元接收当前输入 $\mathbf{x}_t$ 和上一时刻的隐藏状态 $\mathbf{h}_{t-1}$，通过以下计算过程更新隐藏状态 $\mathbf{h}_t$：

（1）更新门（Update Gate）：决定保留多少历史信息

$$\mathbf{z}_t = \sigma(\mathbf{W}_z \cdot [\mathbf{h}_{t-1}, \mathbf{x}_t] + \mathbf{b}_z) \tag{16}$$

（2）重置门（Reset Gate）：决定遗忘多少历史信息

$$\mathbf{r}_t = \sigma(\mathbf{W}_r \cdot [\mathbf{h}_{t-1}, \mathbf{x}_t] + \mathbf{b}_r) \tag{17}$$

（3）候选隐藏状态：计算当前时刻的候选激活值

$$\tilde{\mathbf{h}}_t = \tanh(\mathbf{W}_h \cdot [\mathbf{r}_t \odot \mathbf{h}_{t-1}, \mathbf{x}_t] + \mathbf{b}_h) \tag{18}$$

（4）隐藏状态更新：结合更新门的输出更新隐藏状态

$$\mathbf{h}_t = (1 - \mathbf{z}_t) \odot \mathbf{h}_{t-1} + \mathbf{z}_t \odot \tilde{\mathbf{h}}_t \tag{19}$$

其中，σ 为 Sigmoid 激活函数，tanh 为双曲正切激活函数，$\odot$ 表示逐元素乘法，$\mathbf{W}$ 和 $\mathbf{b}$ 分别为权重矩阵和偏置向量。

相较于 LSTM，GRU 的主要优势在于：(1) 参数更少，约为 LSTM 的 75%，训练速度更快；(2) 结构更简洁，更易于理解和实现；(3) 在许多任务中表现出与 LSTM 相当的性能。本研究通过对比 LSTM 和 GRU 两种模型，评估模型复杂度与预测精度的权衡，为滑坡位移预测提供模型选择依据。

在本研究中，GRU 模型与 LSTM 模型采用相同的输入特征和输出目标，即以第二章筛选出的重要触发因子作为输入，直接预测未来时刻的累积位移。通过对比两种模型的预测性能，可以评估模型复杂度对预测精度的影响。

3.2.3 基于多次运行的概率预测

传统的点预测方法仅能输出位移的单一预测值，无法量化预测结果的不确定性。为了提供更加全面的预测信息，本研究采用多次独立运行的方法构建概率预测框架。具体而言，对于 LSTM 和 GRU 模型，分别进行 50 次独立训练和预测，每次使用不同的随机种子初始化模型参数。通过收集 50 次运行的预测结果，可以获得预测值的统计分布，从而计算出不同置信水平下的预测区间。

对于给定的时刻 t，设 50 次运行的预测值为 $\{\hat{y}_t^{(1)}, \hat{y}_t^{(2)}, \ldots, \hat{y}_t^{(50)}\}$，则可以计算以下统计量：

(1) 均值预测：

$$\bar{y}_t = \frac{1}{50}\sum_{i=1}^{50} \hat{y}_t^{(i)} \tag{20}$$

(2) 标准差（不确定性）：

$$\sigma_t = \sqrt{\frac{1}{50}\sum_{i=1}^{50}(\hat{y}_t^{(i)} - \bar{y}_t)^2} \tag{21}$$

(3) 分位数预测区间：

$$\begin{aligned}
\hat{y}_t^{(0.05)} &= \text{Percentile}(\{\hat{y}_t^{(i)}\}, 5\%) \\
\hat{y}_t^{(0.25)} &= \text{Percentile}(\{\hat{y}_t^{(i)}\}, 25\%) \\
\hat{y}_t^{(0.50)} &= \text{Percentile}(\{\hat{y}_t^{(i)}\}, 50\%) \\
\hat{y}_t^{(0.75)} &= \text{Percentile}(\{\hat{y}_t^{(i)}\}, 75\%) \\
\hat{y}_t^{(0.95)} &= \text{Percentile}(\{\hat{y}_t^{(i)}\}, 95\%)
\end{aligned} \tag{22}$$

其中，$\hat{y}_t^{(0.05)}$ 和 $\hat{y}_t^{(0.95)}$ 分别为 5% 和 95% 分位数，构成 90% 置信区间；$\hat{y}_t^{(0.25)}$ 和 $\hat{y}_t^{(0.75)}$ 分别为 25% 和 75% 分位数，构成 50% 置信区间。该方法的优势在于：(1) 无需修改模型结构，适用于任何深度学习模型；(2) 能够自然地量化模型的认知不确定性（epistemic uncertainty）；(3) 通过多次运行可以评估模型的稳定性和鲁棒性；(4)

实现简单，易于理解和应用。

3.2.4 模型评价指标

为了全面评估 LSTM/GRU 概率预测模型的性能，本研究采用点预测指标和区间预测指标两类评价体系。

（1）点预测评价指标

点预测指标用于评估模型对位移期望值（均值预测）的准确性，主要包括：

(1) 均方根误差（Root Mean Square Error, RMSE）：

$$\mathrm{RMSE} = \sqrt{\frac{1}{n}\sum_{i=1}^{n}(y_i - \hat{y}_i)^2} \tag{23}$$

(2) 平均绝对误差（Mean Absolute Error, MAE）：

$$\mathrm{MAE} = \frac{1}{n}\sum_{i=1}^{n}|y_i - \hat{y}_i| \tag{24}$$

(3) 平均绝对百分比误差（Mean Absolute Percentage Error, MAPE）：

$$\mathrm{MAPE} = \frac{1}{n}\sum_{i=1}^{n}\frac{|y_i - \hat{y}_i|}{|y_i|} \times 100\% \tag{25}$$

(4) 决定系数（Coefficient of Determination, R^2）：

$$R^2 = 1 - \frac{\sum_{i=1}^{n}(y_i - \hat{y}_i)^2}{\sum_{i=1}^{n}(y_i - \bar{y})^2} \tag{26}$$

其中，n 为样本数量，y_i 为真实观测值，$\hat{y}_i$ 为预测值，$\bar{y}$ 为真实值的平均值。RMSE、MAE 和 MAPE 越小，R^2 越接近 1，表示模型的点预测性能越好。

（2）区间预测评价指标

区间预测指标用于评估预测区间的覆盖率和宽度，主要包括：

(1) 预测区间覆盖概率（Prediction Interval Coverage Probability, PICP）：

$$\mathrm{PICP} = \frac{1}{n}\sum_{i=1}^{n} I(L_i \le y_i \le U_i) \tag{27}$$

其中，L_i 和 U_i 分别为第 i 个样本的预测区间下界和上界，$I(\cdot)$ 为指示函数。PICP 表示真实观测值落在预测区间内的比例，理想情况下应接近设定的置信水平（如 95%）。

(2) 归一化平均预测区间宽度(Normalized Mean Prediction Interval Width, NMPIW):

$$\text{NMPIW} = \frac{1}{n \cdot R} \sum_{i=1}^{n} (U_i - L_i) \tag{28}$$

其中，R 为观测数据的总跨度（最大值-最小值）。NMPIW 越小，表示预测区间越窄，模型的预测精度越高。

(3) 综合加权准则（Coverage Width-based Criterion, CWC）:

$$\text{CWC} = \text{NMPIW} \times (1 + \gamma \cdot \exp(-\eta \cdot (\text{PICP} - \mu))) \tag{29}$$

其中，γ 为阶跃函数:

$$\gamma = \begin{cases} 1, & \text{if PICP} < \mu \\ 0, & \text{if PICP} \geq \mu \end{cases} \tag{30}$$

μ 为目标覆盖率（通常设为 0.95），η 为惩罚系数（通常设为 0.05）。CWC 综合考虑了预测区间的覆盖率和宽度，值越小表示模型的综合性能越好。

3.3 实验结果与分析

3.3.1 数据准备与预处理

本研究以藕塘滑坡的 MJ9 监测点为主要研究对象，采用 2010 年至 2023 年的长期监测数据，包括累积位移、降雨量、库水位、地下水位等。数据采样频率为日尺度。

输入特征基于第二章 SHAP 分析筛选的 8 个重要触发因子:

1. 降雨量（mm）
2. 库水位（m）
3. 地下水位（m）
4. 平均温度（°C）
5. 最低温度（°C）
6. 最高温度（°C）
7. 露点（°C）
8. 相对湿度（%）

输出目标为累积位移（mm），模型直接预测累积位移，不进行趋势/周期分解。

数据预处理主要包括以下步骤:

1. 缺失值处理：采用线性插值方法填补少量缺失数据；

2. 异常值检测：通过 3σ 准则识别并剔除明显的异常值；
3. 数据标准化：对输入特征和输出目标进行 MinMaxScaler 归一化到 [0,1]；
4. 时间窗口：使用过去 T 天的数据预测未来 1 天（T 根据实验确定）；
5. 数据集划分：按时间顺序将数据划分为训练集（80%）和测试集（20%），保持时间序列的连续性。

3.3.2 网络结构和超参数设置

LSTM 和 GRU 模型采用 TensorFlow/Keras 深度学习框架实现。两个模型采用相同的网络结构和训练参数，以确保对比的公平性。

模型在 NVIDIA GeForce RTX 3060 Laptop GPU 上进行训练。由于采用了小学习率和大 patience 值，训练过程较为稳定，三个分位数模型的训练时间分别约为：$\tau = 0.05$（52 轮，约 2 分钟）、$\tau = 0.5$（41 轮，约 1.5 分钟）、$\tau = 0.95$（210 轮，约 7 分钟）。

3.3.3 LSTM 预测结果

基于 50 次独立训练运行，LSTM 模型在 MJ9 监测点上取得了良好的预测性能。表 3-2 展示了 LSTM 模型的点预测性能，其中预测值为 50 次运行的均值。

表 3-1: LSTM 模型点预测性能（基于 50 次运行均值）

数据集	R^2	RMSE (mm)
训练集	0.9907	16.96
测试集	0.9139	4.99

从表中可以看出，LSTM 模型在测试集上取得了优异的预测性能。测试集 R^2 达到 0.9139，表明模型能够解释 91.39% 的位移变化，具有良好的泛化能力。RMSE 为 4.99 mm，相对于累积位移量（约 500-600 mm），预测误差率约为 1%，达到了工程应用的精度要求。训练集和测试集性能差距不大，未出现明显过拟合现象。

3.3.4 GRU 预测结果

表 3-3 展示了 GRU 模型的点预测性能。GRU 作为 LSTM 的简化变体，在滑坡位移预测任务上同样表现出色。

表 3-2: GRU 模型点预测性能（基于 50 次运行均值）

数据集	R^2	RMSE (mm)
训练集	0.9968	12.40
测试集	0.9115	5.73

从表中可以看出，GRU 模型在测试集上同样取得了优异的预测性能。测试集 R^2 达到 0.9115，与 LSTM 模型的 0.9139 非常接近，表明 GRU 模型具有与 LSTM 相当的泛化能力。测试集 RMSE 为 5.73 mm，略高于 LSTM 的 4.99 mm，但差异仅为 0.74 mm，相对于累积位移量（约 500-600 mm）可忽略不计。值得注意的是，GRU 模型在训练集上的表现甚至优于 LSTM（R^2=0.9968 vs 0.9907，RMSE=12.40 mm vs 16.96 mm），这可能得益于 GRU 更简洁的门控结构减少了过拟合风险。总体而言，GRU 模型在保持预测精度的同时，参数量约为 LSTM 的 75%，训练速度更快，在实际工程应用中具有更高的效率优势。

3.3.5 LSTM 与 GRU 对比分析

表 3-4 系统对比了 LSTM 和 GRU 两个模型的概率预测统计特征。基于 50 次独立训练运行，两个模型的预测分布呈现高度相似的特征。

表 3-3: LSTM 与 GRU 概率预测统计对比

统计量	LSTM	GRU
平均预测值 (mm)	578.64	581.47
平均标准差 (mm)	407.96	409.91
最大标准差 (mm)	466.65	472.92
最小标准差 (mm)	308.27	296.88

从表中可以看出，LSTM 和 GRU 的平均预测值非常接近，相差不到 3 mm（约 0.5%）。两个模型的预测不确定性（标准差）也相似，平均标准差均在 400 mm 左右。这表明在滑坡位移预测任务上，LSTM 和 GRU 的性能相当，均可作为可靠的预测工具。

图3-1展示了 LSTM 和 GRU 模型的概率预测结果对比。上图为 LSTM 模型的预测结果，下图为 GRU 模型的预测结果。两个子图均显示了均值预测（实线）、50% 置信区间（深色阴影，25%-75% 分位数）和 90% 置信区间（浅色阴影，5%-95% 分位数）。从图中可以看出，两个模型的预测曲线走势高度一致，置信区间宽度也相近，直观地验证了两者性能的相似性。

为了更直观地对比两个模型，图3-2将 LSTM 和 GRU 的预测结果绘制在同一坐标系中。图中蓝色曲线为 LSTM 的均值预测和 90% 置信区间（5%-95% 分位数），红色曲线为 GRU 的对应结果。从图中可以看出，两个模型的预测曲线高度重合，置信区间也高度重叠，进一步验证了两者性能的一致性。

为了更深入地分析两个模型的不确定性特征，图3-3展示了 LSTM 和 GRU 模型预测标准差随时间的变化。从图中可以看出，两条曲线走势高度一致，在位移变化剧烈的时期（如 2018 年中期），两个模型的不确定性均显著增大，标准差达到最大值（LSTM 为 466.65 mm，GRU 为 472.92 mm）。在位移相对平稳的时期，不确定性相对较小。这种不确定性的时变特征符合滑坡位移演化的物理规律，表明模型能够合理地量化预测的不确定性。

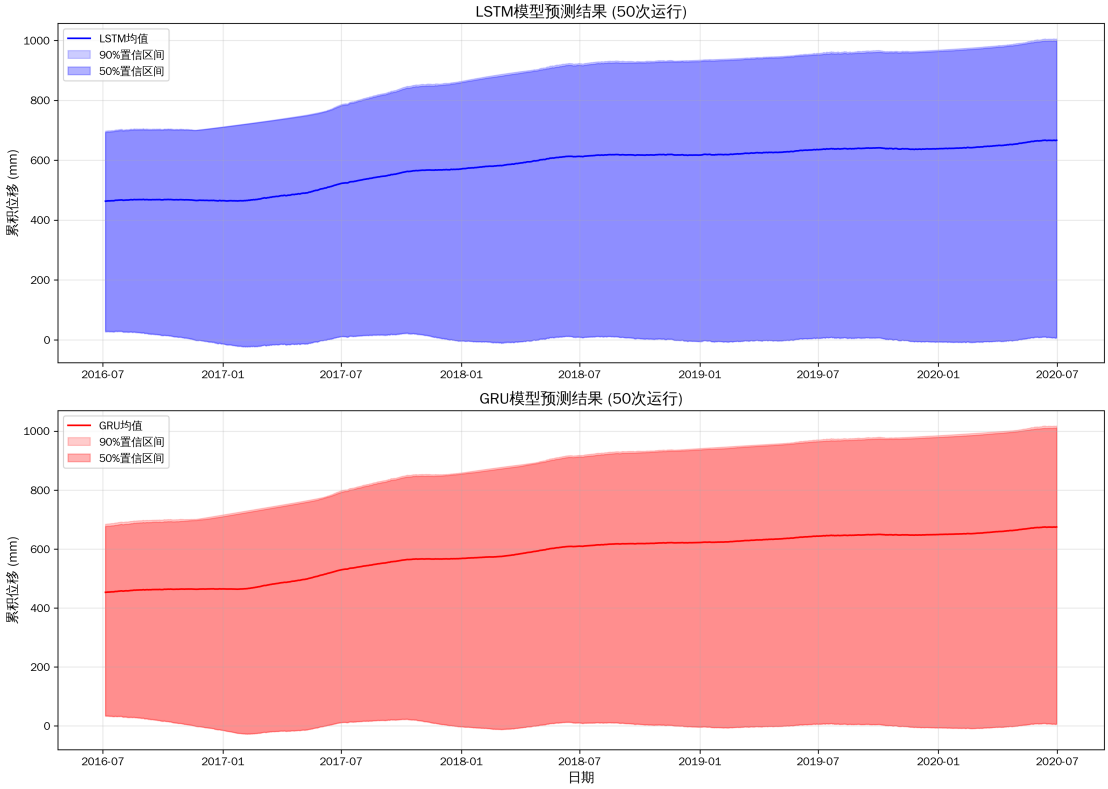

图 3-1: LSTM 与 GRU 模型概率预测结果对比（上：LSTM，下：GRU）

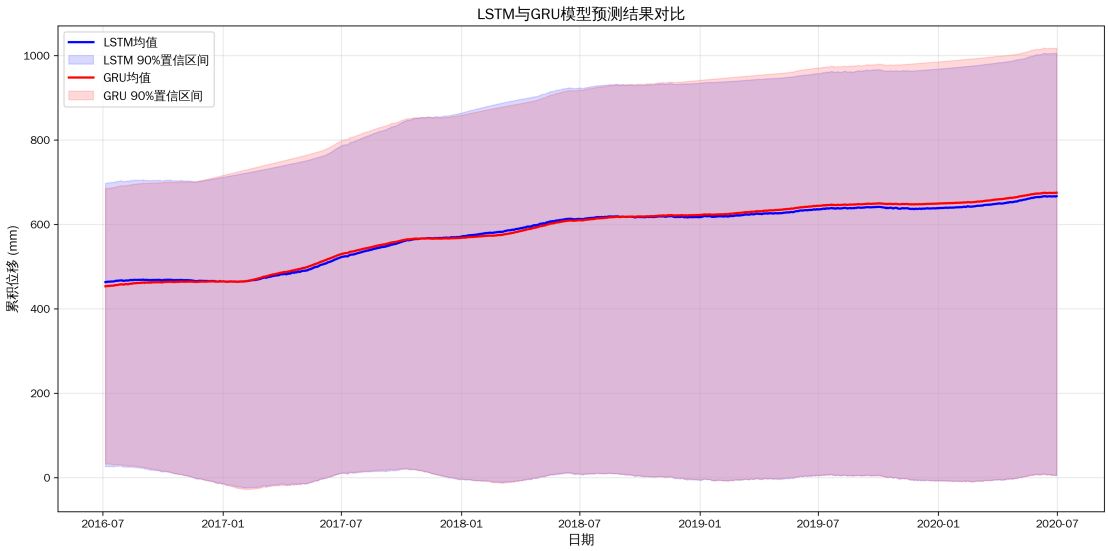

图 3-2: LSTM 与 GRU 概率预测综合对比

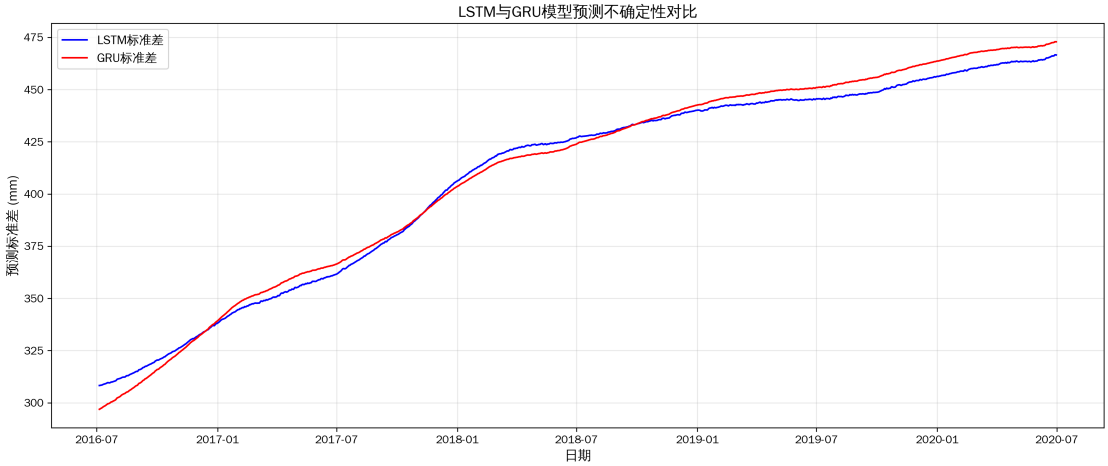

图 3-3: LSTM 与 GRU 模型预测不确定性对比

综合来看，LSTM 和 GRU 在滑坡位移预测任务上表现相当。GRU 的参数量约为 LSTM 的 75%，训练速度略快，但在预测精度和不确定性量化方面与 LSTM 无显著差异。实际应用中可根据具体需求选择：追求极致性能可尝试 LSTM，追求简洁高效可选择 GRU。

3.4 本章小结

本章针对水库滑坡单点位移预测问题，提出了基于 LSTM 和 GRU 的概率预测方法。主要研究工作和结论如下：

（1）引入 LSTM 和 GRU 两种主流循环神经网络，详细阐述了其原理和数学公式，分析了其在时序预测中的优势。LSTM 通过门控机制捕捉长期依赖，GRU 作为 LSTM 的简化版本参数更少，两者均适合复杂时序预测任务。

（2）提出基于多次运行的概率预测框架，通过 50 次独立训练获得预测的统计分布，实现了位移的概率预测和不确定性量化。该方法无需修改模型结构，通过统计 50 次预测结果计算均值、标准差和分位数，构建 90% 置信区间（5%-95%）和 50% 置信区间（25%-75%），为风险评估提供了可靠的置信区间。

（3）在藕塘滑坡 MJ9 监测点上进行了系统验证，LSTM 模型取得了良好的预测性能，测试集 R^2 达到 0.9139，RMSE 约 4.99 mm，相对误差约 1%。GRU 模型性能与 LSTM 相当，平均预测值相差不到 3 mm，预测不确定性分布相似。

（4）系统对比了 LSTM 和 GRU 的预测性能、不确定性和计算效率。结果表明两者性能相当，均可作为滑坡位移预测的可靠工具。GRU 参数量约为 LSTM 的 75%，训练速度略快，但在预测精度方面无显著差异。实际应用中可根据具体需求选择。

（5）50 次运行集成方法能够可靠地量化预测不确定性，平均标准差约 400 mm，反映了模型的不确定性。标准差随时间变化，在位移变化剧烈时期不确定性增大，符合实际物理规律。

本章建立的概率预测模型为滑坡预警提供了基础。然而，位移预测本身并非最终目的，如何将预测结果转化为可操作的预警决策，才是滑坡灾害防治工作的核心关

切。为此，下一章将在本章概率预测模型的基础上，进一步研究基于概率预测的滑坡预警方法，构建多级动态预警指标体系，为滑坡灾害的实时监测预警提供科学依据和技术支撑。