基于机器学习方法的水库滑坡位移预测及预警研究——以藕塘滑坡为例

韦承谦

2026 年 3 月 29 日

目录

一 绪论 **3**
1.1 研究意义和目的 3
1.1.1 理论意义 3
1.1.2 现实意义 3
1.1.3 目的 3
1.2 滑坡位移预测研究现状（国内外研究现状） 4
1.2.1 国外研究动态 4
1.2.2 国内研究动态 5
1.3 滑坡预警研究现状 5
1.4 主要研究内容及技术路线 6
1.4.1 主要研究内容 6
1.4.2 拟解决的主要问题 6
1.4.3 技术路线 7

二 基于机器学习的水库滑坡时空位移预测及预警研究 **7**
2.1 前言 7
2.2 工程概况 9
2.3 研究方法 9
2.3.1 算法流程 10
2.3.2 可解释机器学习模型 10
2.3.3 候选特征选择 12
2.3.4 藕塘滑坡变形机制分析 13
2.4 结果及讨论 14
2.4.1 数据准备与模型构建 14
2.4.2 模型性能评估 15
2.4.3 SHAP 可解释性分析 16

2.4.4 讨论 18
2.5 本章小结 19

三 基于位移运动学特征的滑坡位移预测模型研究 20
3.1 前言 20
3.2 方法原理 21
3.2.1 长短期记忆网络（LSTM） 21
3.2.2 基于多次运行的概率预测 22
3.2.3 模型评价指标 23
3.3 实验结果与分析 24
3.3.1 数据准备与预处理 24
3.3.2 网络结构和超参数设置 25
3.4 预测结果与分析 26
3.4.1 点预测性能评价 26
3.4.2 概率预测结果分析 26
3.4.3 不确定性分析 27
3.5 本章小结 28

四 基于概率预测的滑坡预警方法研究 30
4.1 前言 30
4.2 基于概率预测的动态预警指标体系 31
4.2.1 预警阈值设定依据 31
4.2.2 核心指标：基于经验分布的越限概率 31
4.2.3 预警等级划分标准 33
4.3 藕塘滑坡动态概率预警案例验证 34
4.3.1 监测点选择与预警实施流程 34
4.3.2 MJ1 监测点预警结果分析 35
4.3.3 MJ9 与 MJ3 监测点预警结果 38
4.3.4 基于 SHAP 的预警结果归因解释 39
4.4 预警方法对比与性能评估 40
4.4.1 传统速率预警方法 40
4.4.2 预警性能量化评估 40
4.4.3 预警方法对比讨论 41
4.5 本章小结 42

五 结论 43

一　绪论

1.1　研究意义和目的

1.1.1　理论意义

本研究针对大型水库滑坡内部变形空间不均匀及多场耦合机制复杂的科学难题，旨在突破传统单点位移预测模型割裂滑坡体时空联系的局限性。三峡库区特大型滑坡（如藕塘滑坡）通常具有显著的分区、分级变形特征，传统的时间序列分析方法往往难以揭示滑坡后缘推力与前缘阻滑效应之间的力学传递规律。本课题通过构建基于时空图神经网络的预测架构，将滑坡视为一个有机互馈的动力学系统，有助于从数据驱动的视角厘清滑坡不同块体间的协同演化机制与链式响应规律，为完善复杂岩土介质的非线性动力学理论提供新的切入点。此外，针对深度学习模型普遍存在的”黑箱”问题，本研究引入注意力机制与特征归因分析方法，致力于定量解析库水位涨落与降雨入渗对滑坡位移的”滞后衰减效应”及贡献权重。这种尝试不仅赋予了机器学习模型以明确的物理可解释性，也为揭示”水-土”相互作用下阶跃型滑坡的成因机理提供了可量化的数据支撑，实现了从纯粹的数据挖掘向地质机理反演的理论跨越。

1.1.2　现实意义

本课题的研究成果对于提升三峡库区重大地质灾害的防灾减灾水平具有重要的应用价值。藕塘滑坡作为三峡库区体积巨大、变形机制复杂的典型涉水滑坡，其稳定性直接关系到长江黄金水道的通航安全及库区沿岸居民的生命财产安全。本研究构建的高精度时空位移预测模型，旨在解决传统方法在极端水文气象工况（如库水位急剧下降叠加持续强降雨）下预测精度失效的难题，力争实现对滑坡灾变趋势的亚毫米级精准把控。更为关键的是，本研究不再满足于单一的位移数值预报，而是建立基于置信区间的动态概率预警体系。这将为地质灾害防治部门提供包含风险概率的科学决策依据，有效降低因监测噪声或局部扰动导致的误报率与漏报率。通过显著延长有效预警的时间窗口，本研究可为制定库水位应急调度方案、实施航道交通管制以及组织人员避险转移争取宝贵的”黄金时间”，从而最大限度地降低潜在的灾害风险与社会经济损失。

1.1.3　目的

本研究旨在通过运用岩土工程与计算机科学交叉学科知识，巩固深化岩土力学、边坡工程及机器学习算法的基本理论，学习和理解滑坡演化机理及预测预警的前沿方法。具体目标包括：

1. 通过查阅国内外文献，系统掌握机器学习在滑坡位移预测中的原理和方法，梳理该领域的研究现状与发展趋势；

2. 选取三峡库区典型阶跃型滑坡——藕塘滑坡为研究对象，深入分析滑坡累积位移与库水位周期性涨落、季节性降雨等外部诱发因子之间的非线性关系及滞后规律；

3. 基于 Python 环境（PyTorch 框架）构建机器学习预测模型，通过数据处理、特征工程、模型构建及结果分析的全过程训练，掌握数据驱动的滑坡位移预测方法与步骤；

4. 引入不确定性分析方法，构建滑坡位移的概率预测区间，制定科学的滑坡分级预警判据，为防灾减灾提供决策依据；

5. 通过建立机器学习预测模型的全过程训练，获得科研工作的基本训练，提高分析复杂岩土工程问题和解决问题的能力。

1.2 滑坡位移预测研究现状（国内外研究现状）

1.2.1 国外研究动态

国外在滑坡灾害预测与预警领域的研究起步较早，近年来，该领域正经历着从单一物理模型向" 数据-物理" 深度融合的范式转变。最新的国际研究趋势不再局限于对监测数据的简单数值拟合，而是更加强调机器学习模型在复杂地质环境下的物理一致性与泛化能力。特别是在物理信息机器学习（PIML）领域，研究重心已显著转向将非饱和土力学中的控制方程或边坡稳定性物理约束直接嵌入神经网络的损失函数中，以解决小样本条件下的" 黑箱" 不可靠难题。

在监测技术与空间协同预警方面，构建大范围区域的滑坡灾害时空动态感知系统已成为主流。最新的国际学术期刊研究显示，利用合成孔径雷达干涉测量（InSAR）技术获取地表形变场，并结合深度学习算法构建区域滑坡动态评估框架是当前的热点。例如，Zhang 等 [29] 提出了一种融合空间图神经网络（GCN）与时间卷积网络（TCN）的时空位移预测模型（GMTC）。该研究利用 Sentinel-1A 卫星数据对滑坡进行三维形变分解，并通过多头自注意力机制捕捉滑坡形变在时空维度的非线性动态特征，显著优于传统的 GRU 和 GCN 模型，实现了对滑坡位移的高精度预测。

此外，针对人工智能在防灾减灾决策中的信任问题，可解释性人工智能（Explainable AI, XAI）已成为当前国际滑坡研究的重要方向。为了将复杂的机器学习预测结果转化为决策者可理解的预警信息，国际学者引入了 SHAP（Shapley Additive explanations）等归因分析方法。例如，Al-Najjar 等 [30] 针对滑坡易发性建模中的" 黑箱" 问题，利用 SHAP 方法对随机森林模型的预测结果进行了全方位的解释。该研究不仅量化了地质环境因子（如地形、地质构造等）对模型预测的非线性贡献度，还通过可视化手段展示了特征交互作用，为制定科学的风险管控策略提供了强有力的理论依据，有效弥合了复杂算法与实际防灾应用之间的鸿沟。

1.2.2 国内研究动态

中国作为世界上水库滑坡灾害最为频发的国家之一，特别是三峡库区，其特殊的地质环境与周期性的库水位涨落（145 米至 175 米）叠加季节性强降雨，使得滑坡演化机制极为复杂。针对水库滑坡特有的”阶梯状”演化特征，国内学术界已经建立了一套相对成熟的”时序分解-多源重构-组合预测”研究范式。早期的研究主要致力于解决非线性位移数据的降噪与分量提取问题，广泛采用了变分模态分解（VMD）、改进自适应噪声完备集合经验模态分解（ICEEMDAN）等信号处理技术。例如，马佳伟等 [12] 建立了一种基于 ICEEMDAN-CNN-BiLSTM-XGBoost 的双层融合预测模型，有效解决了传统模型在位移分解中存在的模态混叠问题。在此基础上，国内学者通过引入智能优化策略，构建混合预测模型。唐宇峰等 [10] 提出的 PSO-GRU-OL-MRT 模型，通过深度挖掘位移监测数据与诱发因子之间的高维非线性映射关系，显著提升了滑坡位移的实时预测精度。

随着人工智能技术的迭代升级，国内研究重点正逐步从传统的递归神经网络向基于注意力机制（Attention Mechanism）和 Transformer 架构的第三代深度学习模型演进。针对传统模型难以量化降雨和库水位”滞后效应”的痛点，最新的研究工作通过在模型中嵌入自注意力模块，实现了对多源诱发因子长时序依赖关系的动态捕捉。汪松林等 [18] 构建了基于特征增强的 Transformer-GRU 模型，该模型不仅能够自动识别不同变形阶段的关键驱动因子，还能通过可视化权重分配，从数据层面反演滑坡对水文气象条件的响应规律。与此同时，针对特大型涉水滑坡（如藕塘滑坡）往往存在多级滑体且各部位变形不同步的特征，国内学者开始探索基于时空协同的预测新模式。高振武等 [20] 提出了一种基于多测点时空模态信息互馈的阶跃式滑坡位移预测方法，通过融合多测点的时空模态信息，有效解决了局部监测噪声干扰导致的误报问题。

1.3 滑坡预警研究现状

在预警决策与风险评估方面，国内外研究正在推动从确定性的”点预测”向不确定性的”概率区间预测”跨越，旨在解决单纯数值预测无法量化风险可信度的问题。鉴于滑坡系统的随机性与模糊性，部分前沿学者将核密度估计（KDE）理论与深度学习预测结果相结合，构建了包含置信区间的概率预测模型，实现了对位移波动范围的科学度量。例如，王石等 [11] 提出了基于 SSA-CNN-BiLSTM-AM 和 KDE 的滑坡位移混合点-区间预测方法，该方法不仅提供了位移的点预测值，还通过 KDE 方法构建了预测区间，量化了预测结果的不确定性，为滑坡预警提供了更加可靠的决策依据。

更为深入的研究则进一步将位移预测延伸至物理力学层面的稳定性评估，提出了考虑滑带土应变软化特性的时变失效概率分析方法。通过建立滑坡稳定系数与库水位变动、降雨入渗及累积变形之间的动态响应方程，研究人员实现了对滑坡全生命周期灾变风险的动态追踪。孟轩宇 [3] 针对三峡库区阶跃型库岸滑坡，提出了时变失效概率预测方法，该方法综合考虑了库水位涨落、降雨入渗以及滑带土应变软化等多重因素对滑坡稳定性的影响，实现了对滑坡灾变风险的定量评估。Zou 等 [23] 以藕塘滑坡为例，提出了一种评估水库滑坡时变稳定性的新方法，该方法通过建立滑坡稳定系

数与环境因子之间的动态响应模型，实现了对滑坡稳定性的实时监测与预警。

这种融合了”数据驱动的高精度预测”与”物理驱动的稳定性评价”的综合研究体系，标志着国内外水库滑坡防灾减灾技术正朝着精细化、智能化和实用化的方向迈进。通过将机器学习的强大预测能力与岩土工程的物理机理相结合，不仅提高了滑坡位移预测的精度，还增强了预警系统的可靠性和可解释性，为地质灾害防治部门提供了更加科学、全面的决策支持。

1.4 主要研究内容及技术路线

1.4.1 主要研究内容

本研究以三峡库区典型阶跃型滑坡——藕塘滑坡为研究对象，围绕机器学习方法在水库滑坡位移预测及预警中的应用展开系统研究。主要研究内容包括以下三个方面：

滑坡变形演化机理与多源特征工程构建 深入分析藕塘滑坡累积位移与库水位周期性涨落、季节性降雨等外部诱发因子之间的非线性关系及滞后规律。对长序列监测数据进行清洗、降噪及归一化处理，利用可解析性机器学习方法（如 LightGBM+SHAP）筛选出主控影响因子，定量评估各触发因子对滑坡位移的贡献度。通过特征重要性分析、局部依赖图和特征交互效应图等多维度可视化手段，揭示水文气象因素与滑坡变形之间的内在非线性映射关系，完成多源特征工程的构建，为模型训练提供高质量的输入数据。

基于机器学习的滑坡位移预测模型搭建与对比 基于 Python 环境（PyTorch 框架）搭建机器学习预测模型。针对滑坡变形的时空演化特征，探索不同机器学习算法在位移预测中的应用，重点解决多源数据融合及长时序依赖问题。通过开展对比实验，分析不同模型在预测精度（RMSE、MAE、R^2）与泛化能力上的差异，重点关注阶跃变形期的预测效果，优选出适用于藕塘滑坡的最佳预测模型。

滑坡位移不确定性分析与概率预警研究 针对确定性点预测难以反映结果可信度的问题，引入不确定性分析方法，构建滑坡位移的概率预测区间。基于测试集的预测误差，利用统计分析方法（如核密度估计 KDE 等）生成误差概率密度函数，构建一定置信水平下的预测区间，并计算区间覆盖率（PICP）和平均带宽（MPIW）评价区间质量。量化模型预测结果的波动范围与置信度，实现从单一数值预报向区间概率预报的转变。在此基础上，结合统计学准则或变形速率阈值，制定科学的滑坡分级预警判据，为防灾减灾提供决策依据。

1.4.2 拟解决的主要问题

本研究针对水库滑坡位移预测与预警中的关键科学问题，拟重点解决以下三个方面的难题：

多源诱发因子的”最佳时滞”特征优选问题 库水位和降雨对滑坡的影响具有显著的滞后性与非线性特征。拟解决如何从海量监测数据中，精准识别出降雨和库水位影响滑坡变形的最优滞后时间窗口。通过有效的特征选择与降维策略，剔除冗余特征干扰，提高模型输入变量的物理相关性与有效性，解决多源数据输入的高维冗余难题。

阶跃型滑坡”突变点”的预测削峰与滞后问题 常规机器学习模型在滑坡位移加速变形期（阶跃点）容易出现”削峰”现象（预测值偏低）或相位滞后，难以捕捉极端工况下的突变特征。拟解决如何通过改进模型架构或引入特征增强策略，提升模型对暴雨、水位急降等强激发条件下位移非线性动态变化的敏感性，进而提高阶跃变形期的峰值预测精度。

预测结果的不确定性量化与预警可靠性问题 传统确定性点预测无法反映预测结果的可信度。拟解决如何构建包含置信度的概率预测区间，量化模型的不确定性风险，为滑坡预警提供更科学的决策依据。通过建立基于概率区间的动态预警体系，有效降低因监测噪声或局部扰动导致的误报率与漏报率。

1.4.3 技术路线

本研究的技术路线如图1-1所示，主要包括数据采集与预处理、特征工程构建、模型训练与优化、概率预警体系构建四个核心环节。

二 基于机器学习的水库滑坡时空位移预测及预警研究

2.1 前言

在构建数据驱动的水库滑坡时空位移预测模型时，输入特征的科学选取直接决定了模型的预测精度与泛化能力。传统基于经验的特征选择方法虽具备一定的工程地质学基础，但在处理复杂非线性的监测数据时往往带有较强的主观性，难以定量刻画各诱发因素的具体影响程度，缺乏统一的标准。为此，本章引入高效的梯度提升框架（LightGBM）与可解释性机器学习工具（SHAP），旨在对滑坡变形的候选驱动因子进行精准的定量评估与优选。本研究以典型的藕塘滑坡为案例，针对其复杂的地质演化特征，收集并整理了该区域长时间序列的库水位、降雨量及地表时空位移等监测数据。基于 LightGBM 模型的高效拟合能力，结合 SHAP 方法深入剖析各输入特征对滑坡时空位移的贡献度。通过特征重要性图、局部依赖图和特征交互效应图等多维度的可视化分析，系统揭示水文气象因素与滑坡变形之间的内在非线性映射关系。本章采用”先验知识指导初筛 + 数据算法量化验证”的研究策略，不仅有效克服了传统机器学习模型”黑盒”特性的不足，提升了特征选择的科学性与物理可解释性，更为后续构建高精度的藕塘滑坡时空位移预测及预警模型奠定了坚实的数据基础与理论支撑。

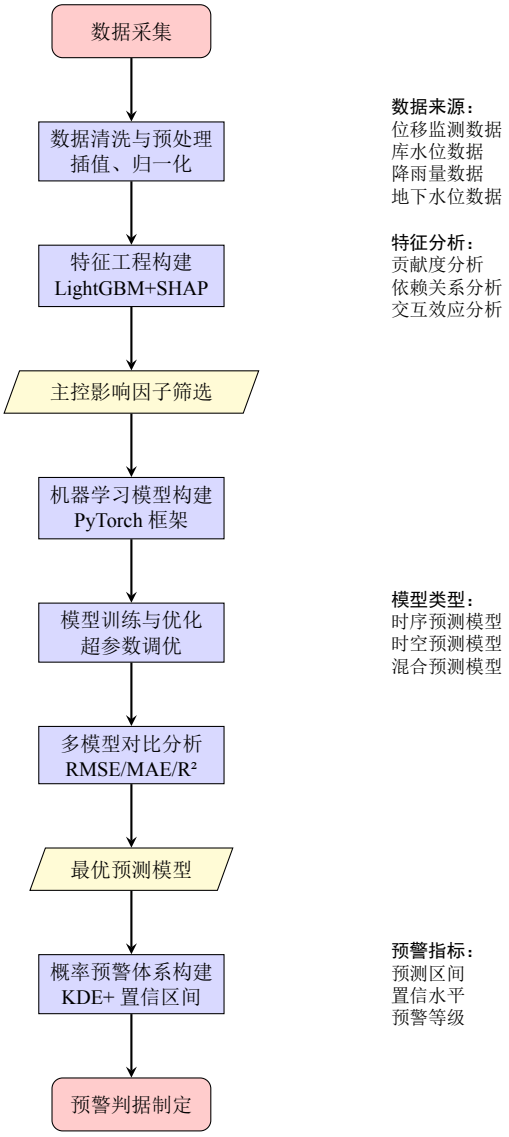
数据采集
数据清洗与预处理
插值、归一化
特征工程构建
LightGBM+SHAP
主控影响因子筛选
机器学习模型构建
PyTorch 框架
模型训练与优化
超参数调优
多模型对比分析
RMSE/MAE/R²
最优预测模型
概率预警体系构建
KDE+ 置信区间
预警判据制定
数据来源：
位移监测数据
库水位数据
降雨量数据
地下水位数据
特征分析：
贡献度分析
依赖关系分析
交互效应分析
模型类型：
时序预测模型
时空预测模型
混合预测模型
预警指标：
预测区间
置信水平
预警等级

图 1-1: 技术路线图

2.2 工程概况

本研究以典型的阶跃型水库滑坡——藕塘滑坡为核心研究对象。藕塘滑坡位于三峡库区重庆市奉节县安坪镇的长江南岸，属于构造剥蚀的中低山河谷地貌。该区域地形总体呈南高北低之势，滑坡体后缘高程达 700 余米，前缘直抵长江干流，整体坡度多在 15° 至 30° 之间。研究区出露地层主要以侏罗系（J）的泥岩、砂质泥岩与粉砂岩互层为主，这种软硬相间的岩层结构在长期风化和水流侵蚀下，极易形成软弱滑动面。

在气候与水文条件方面，该地区属于亚热带季风气候，年平均气温约为 18°C，多年平均降水量在 1100 毫米左右。降水在年内分配极不均匀，主要集中在每年的 5 月至 9 月，且多以暴雨形式出现。此外，三峡水库的周期性调度对滑坡的稳定性影响显著。库水位每年在 145 米至 175 米之间进行季节性的大幅波动：通常于 9 月开始蓄水，年末达到并维持 175 米高水位，次年春季逐步消落至 145 米防洪限制水位。

研究区域的地下水动态受大气降水和水库蓄水双重控制。频繁的库水位升降交替与季节性强降雨的耦合作用，不断改变着坡体的渗流场与应力状态。鉴于藕塘滑坡体量巨大、地质条件复杂且变形响应极其敏感，将其作为此时空位移预测及预警模型研究的案例，具有重要的科学意义与防灾减灾实践价值。

2.3 研究方法

在明确了滑坡变形的潜在触发因子后，本文采用 LightGBM 模型探索藕塘滑坡时空位移变形与降雨、库水位、地下水位及温度等相关特征之间的关系。为了进一步提高模型的透明度和可解释性，本文结合 SHAP 方法对 LightGBM 模型进行了解释。通过对历史监测数据的分析，识别出可能导致滑坡变形的关键因素，其主要流程如下：

首先，在藕塘滑坡区域选择具有代表性的位移监测点（MJ9、MJ1、MJ3），获取长期监测数据。同时根据降雨、库水位、地下水位及气象条件选择相关的触发因子。本研究基于触发因子和监测点的位移数据训练 LightGBM 模型，并利用 SHAP 方法对模型进行解释。

在 LightGBM 模型训练阶段，结合滑坡体的地质背景与已知变形规律，初步筛选具有物理意义的特征因子，通过 SHAP 方法进一步挖掘其对模型预测的贡献与影响形式。通过 SHAP 贡献图、依赖图和交互图，分析不同因子对模型预测结果的贡献，包括：

1. 贡献图分析：各触发因子对 LightGBM 模型位移预测的贡献大小；
2. 依赖图分析：单个触发因子的取值变化如何影响模型的位移预测；
3. 交互图分析：两个触发因子交互时，不同特征值组合对位移预测的影响。

通过上述”LightGBM+SHAP” 方法的分析与解释，本研究从定量层面揭示了各触发因子的独立贡献、滑坡对不同触发因子变化的非线性响应和对触发因子之间的非线性耦合机制的响应，为后续滑坡时空位移预测及预警建模提供支持。

2.3.1 算法流程

本研究的技术路线如图 2-1所示，主要包括数据采集、模型训练、可解释性分析三个核心环节。

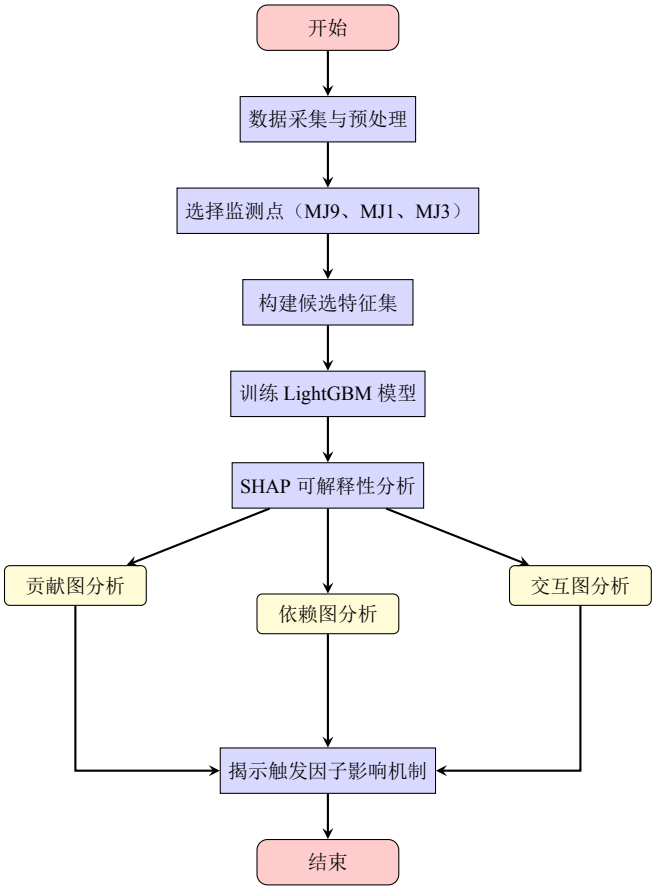

图 2-1: 基于 LightGBM+SHAP 的滑坡位移预测算法流程图

2.3.2 可解释机器学习模型

LightGBM 模型 LightGBM 是一种高效的梯度提升树（GBDT）框架，广泛应用于大规模机器学习任务，尤其是在数据量大且高维度特征的情况下。LightGBM 通过对传统梯度提升树（GBDT）算法进行优化，提供了更高的计算效率、内存消耗更低，同时具有较强的泛化能力，适用于分类、回归、排序等多种任务。LightGBM 的核心思想与传统的梯度提升方法相同，都是通过集成多个决策树来提升模型的预测性能。通过不断添加新的树来拟合误差，并结合多个树的输出，生成最终的预测结果。但 LightGBM 在此基础上做了一些重要的优化，使得它能够更高效地处理大规模数据集。

LightGBM 在梯度提升树的基础上，采用了以下关键技术：

1. **直方图算法：**通过将连续特征值离散化为多个区间，在构建树时使用这些区间来选择分裂点，从而减少了计算量并提高了训练效率。特别是在处理高维数据时，直方图算法表现出显著的优势。

2. **叶子生长策略**：传统的 GBDT 采用层级生长策略，即在每一层分裂中分配节点，而 LightGBM 采用叶子生长策略。在这种策略中，LightGBM 优先选择误差最小的叶子进行分裂，从而使得每棵树能够更好地拟合数据，尤其是在训练数据集不平衡时。

3. **基于梯度的单边抽样（GOSS）**：GOSS 技术通过在训练过程中丢弃低梯度的样本，只保留高梯度样本来进行计算。这样可以保留最有信息的样本，提高模型训练的效率。

4. **互斥特征捆绑（EFB）**：EFB 技术将互斥的特征捆绑在一起，从而减少了特征数量，避免了高维特征带来的计算开销。该方法对于稀疏数据集尤为有效。

LightGBM 通过引入直方图算法、叶子生长策略、GOSS 和 EFB 等优化方法，显著提高了梯度提升树在大规模数据集上的训练速度和计算效率。其对类别特征的原生支持、低内存消耗以及并行计算能力，使其在许多实际应用中成为首选的机器学习工具。通过调节超参数和特征选择，LightGBM 能够在不同任务中提供优异的性能。

其 LightGBM 将决策树作为基学习器，表示为：

$$F = \{F_1, F_2, \ldots, F_n\} \tag{1}$$

式中，F_i 表示第 i 个学习器，F 表示所有学习器的集合。

LightGBM 通过多次的迭代不断地提升学习器的性能，每次迭代是为获得一个弱学习器，使迭代损失函数 $L(y, F_t(x))$ 最小，其公式为：

$$F_t(x) = F_{t-1}(x) + f_t(x) \tag{2}$$

式中，$F_{t-1}(x)$、$L(y, F_{t-1}(x))$ 分别为上一次迭代获得的强学习器和损失函数。

计算损失函数的负梯度用于拟合本次迭代损失近似值，其公式为：

$$r_{ti} = -\left[\frac{\partial L(y_i, F_{t-1}(x_i))}{\partial F_{t-1}(x_i)}\right] \tag{3}$$

目标函数通常为平方差，使用平方差近似拟合为：

$$f_t(x) = \arg\min \sum_i (r_{ti} - f(x_i))^2 \tag{4}$$

最终获得本次迭代获得的强学习器为：

$$F_t(x) = F_{t-1}(x) + \eta f_t(x) \tag{5}$$

LightGBM 模型通过以上方式不断更新，采用 histogram 算法减少内存的使用和计算的复杂度，使用 Leaf-wise 的叶子优先生长策略，并通过设置最大树深限制其结构

复杂度。该方法能够在保证精度的前提下加快收敛速度，相较于传统的 Level-wise 方法更适用于大规模数据场景。基于梯度的单边采样（GOSS）和互斥特征捆绑（EFB）减少训练时间。

SHAP 解释模型 SHAP 是基于博弈论的解释方法，用于解释机器学习模型的预测结果，量化了每个特征对单一预测结果的贡献。SHAP 值为每个特征分配一个值，表示该特征对某一预测结果的贡献度。它是一种非常强大的工具，能够帮助我们理解模型是如何根据输入特征做出预测的，尤其对于复杂的模型（如 LightGBM、XGBoost 等树模型）尤为有效。对于给定的输入样本 x 有着 N 个解释变量，解释模型 g 表示特征贡献的线性函数：

$$g(x') = \varphi_0 + \sum_{j=1}^{N} \varphi_j x'_j \tag{6}$$

式中 φ_0 代表模型输出的基本值，N 是所有输入特征的总数，x'_j 是二元变量，表示第 j 个预测变量是否存在（$x'_j = 1$）或不存在（$x'_j = 0$）。$\varphi_j \in \mathbb{R}$ 是样本 x 中第 j 个的 SHAP 值（即特征属性）。

$$\varphi_j = \sum_{S \subseteq N \setminus \{j\}} \frac{|S|!(N - |S| - 1)!}{N!} [f(S \cup \{j\}) - f(S)] \tag{7}$$

其中，S 表示输入的解释变量的子集，$f(S \cup \{j\})$ 和 $f(S)$ 分别是包含和不包含第 j 个特征时模型的预测值。

$$\varphi_{j,k} = \sum_{S \subseteq N \setminus \{j,k\}} \frac{|S|!(N - |S| - 2)!}{2(N - 1)!} \nabla_{jk}(S) \tag{8}$$

此外，为了量化变量之间的配对相互影响，SHAP 交互值被引入用于度量特征之间的交互影响。

$$\nabla_{jk}(S) = f_x(S \cup x_j, x_k) - f_x(S \cup x_j) - f_x(S \cup x_k) + f_x(S) \tag{9}$$

当 $j \neq k$ 时，由于特征 j 和 k 之间的 SHAP 交互值平均分配到 $\varphi_{j,k}$ 和 $\varphi_{k,j}$ 中，因此总的交互影响是 $\varphi_{j,k}$ 和 $\varphi_{k,j}$ 的和。每个变量的主要影响是通过从 SHAP 值中减去 SHAP 交互值来确定的。

2.3.3 候选特征选择

滑坡的候选因素应结合物理机理与数据驱动分析两方面进行综合选取。从物理机制角度来看，滑坡的发生和发展过程通常受多种自然环境与工程活动因素的共同作用，这些因素会影响坡体的应力状态、地下水变化和土体结构稳定性。特别是库水位变化和强降雨事件，常常是诱发滑坡活动的直接触发因素。坡度、地层岩性、软弱结构面等内在地质条件，则决定了滑坡的易发性与演化路径。

在本次的初始特征选择中，参考了前人的研究成果，针对藕塘滑坡的时空位移预测任务，初步筛选出基于时间窗口的滞后特征，包括历史位移、降雨、库水位、地下水位及气象因子，如表2-1所示。

表 2-1: 触发特征的候选因子

候选因素类别	描述
历史位移特征	过去 5 天的位移值 disp$(t-5)$ 至 disp$(t-1)$
降雨特征	过去 5 天的日降雨量 Rainfall$(t-5)$ 至 Rainfall$(t-1)$ [mm]
库水位特征	过去 5 天的库水位 RWL$(t-5)$ 至 RWL$(t-1)$ [m]
地下水位特征	过去 5 天的地下水位 GWT$(t-5)$ 至 GWT$(t-1)$ [m]
平均温度特征	过去 5 天的平均温度 aveT$(t-5)$ 至 aveT$(t-1)$ [°C]
最低温度特征	过去 5 天的最低温度 minT$(t-5)$ 至 minT$(t-1)$ [°C]
最高温度特征	过去 5 天的最高温度 maxT$(t-5)$ 至 maxT$(t-1)$ [°C]
露点特征	过去 5 天的露点 DP$(t-5)$ 至 DP$(t-1)$ [°C]
相对湿度特征	过去 5 天的相对湿度 RH$(t-5)$ 至 RH$(t-1)$ [%]
监测点标识	监测点 one-hot 编码（MJ9、MJ1、MJ3）

2.3.4 藕塘滑坡变形机制分析

藕塘滑坡作为三峡库区典型的水库型滑坡，其位移过程表现出明显的阶跃特征，即在特定时间段内位移突增，而在其他时间段相对稳定。这类位移特征在库区滑坡中具有代表性，通常受到周期性库水位变化和突发性降雨过程的共同驱动。藕塘滑坡地质背景复杂，主要分布于软弱堆积层或顺层结构发育的坡体中，地层结构和物理力学性质使其对外部水动力扰动极为敏感。此外，其所处区域的库水位调控方式及年降雨量水平也具有典型性。因此，在地质构造、水文气象条件相近的背景下，藕塘滑坡呈现出独特的变形响应特征。为深入理解三峡库区滑坡位移的形成与演化规律，有必要进一步分析其滑坡变形机制，揭示库水位与降雨在不同阶段如何共同作用于滑坡体，驱动滑坡变形及失稳过程。

从三峡库区典型滑坡的变形演化过程来看，滑坡体的阶跃式位移通常源于降雨和库水位变化的耦合作用机制。这一机制主要通过以下几种路径对滑坡变形产生影响：

1. **库水位变化引起的软化与卸载作用**：在水库蓄水或调控过程中，库水位的周期性涨落会引发滑坡体前缘的软化和卸载效应。当库水位快速下降时，坡脚支撑力减弱，滑坡体前缘土体失去约束，同时滑坡体内部由于仍处于高孔隙水压力状态，造成剪切应力增大，滑坡体发生应力重分布，进而引发滑动。特别是对于具有顺层结构或软弱夹层的滑坡体，该过程更加显著。

2. **降雨入渗引起的孔隙水压力升高**：持续或强降雨会导致雨水大量入渗，改变滑坡体内部的水文条件。随着入渗深度的增加，孔隙水压力迅速上升，有效应力降低，滑动面抗剪强度减弱，从而诱发滑坡位移。此外，强降雨还可能造成坡面径流侵蚀或沟蚀作用，削弱滑坡体的表层稳定性，加速变形。

3. **库水位与降雨的协同效应**：研究发现，单一因素（仅降雨或仅水位变化）难以充分解释大部分滑坡的突跳式位移行为，而库水位下降与强降雨同时发生时，往往引发滑坡的突发性变形。这是由于两种作用机制相互叠加，共同降低滑坡体的稳定性。例如，在库水位下降期遇上强降雨事件，不仅坡体抗剪强度削弱，而且坡脚卸载增强，极易导致大位移的发生。

4. **地质结构条件的调控作用**：上述变形机制的实际表现形式，还受到滑坡体地质构造的影响。藕塘滑坡广泛发育软弱层或顺倾结构带，岩土体抗剪强度低，对水敏感性强，更容易在外部水动力作用下发生变形破坏。同时，滑带土中黏粒含量高、渗透性差，也促进孔压积聚，加剧滑坡体失稳。

综合前人研究成果可知，藕塘滑坡的变形机理主要体现在以下几个方面：

1. 库水位变化是滑坡变形的核心驱动因素，其中尤以水位快速下降引发的动水压力变化对滑坡体稳定性的影响最为显著；

2. 降雨通过增加孔隙水压力、软化岩土体等作用机制，与库水位变化产生叠加效应，进一步加剧滑坡变形过程；

3. 滑坡体渗透性的差异性也决定了其对水位变化的响应程度，渗透性较差的滑坡在水位骤降时更易出现失稳滑动现象。

2.4 结果及讨论

2.4.1 数据准备与模型构建

本研究基于藕塘滑坡区域的长期监测数据，选取了三个具有代表性的位移监测点（MJ9、MJ1、MJ3）进行分析。监测数据时间跨度覆盖了多个完整的库水位调度周期，包含了丰富的滑坡变形信息。数据集包括日尺度的位移监测值、降雨量、库水位、地下水位以及气象要素（平均温度、最低温度、最高温度、露点、相对湿度）等多维度信息。

在样本构造阶段，采用时间窗口为 5 天的滑动窗口方法，将历史时序数据转化为监督学习样本。对于每个监测点，输入特征包括：该点过去 5 天的位移值、过去 5 天的环境因子（降雨、库水位、地下水位、温度、湿度等）以及监测点的 one-hot 编码。回归任务的目标变量为当天的位移增量（$\Delta u = u_t - u_{t-1}$），用于预测滑坡的时空位移变化；分类任务的目标变量基于位移增量是否超过固定阈值 0.3 mm 来定义，用于判定是否进入预警状态。为了严格防止模型评估中出现隐性的数据泄漏，本研究仅基于训练集的统计分布特征来划定预警阈值。通过对训练集数据的统计分析，设定 0.3 mm 为分类任务的固定阈值。该数值接近 MJ9 监测点训练集的 95% 分位数，同时处于 MJ1 和 MJ3 监测点训练集的 75% 至 90% 分位数之间。这一基于先验训练数据的固定阈值设定，不仅有效捕捉了异常变形信号，还避免了在时序交叉验证中使用全局统计量带来的未来数据泄漏风险，确保了模型评估的严谨性与客观性。

在模型验证策略上, 本研究采用 5 折时序交叉验证（TimeSeriesSplit）对模型性能进行评估。时序交叉验证严格保持数据的时间顺序，每一折中训练集始终位于测试集之前，从而避免了随机划分可能导致的” 未来数据泄漏” 问题，真实模拟了实际预测场景中的时序依赖关系。针对预警样本在时间维度上分布不均匀的问题（预警事件往往集中在特定时期），本研究在每一折的训练阶段引入 SMOTE（Synthetic Minority Over-sampling Technique）过采样技术，仅对训练集中的少数类样本进行合成扩充，以缓解类别不平衡对分类模型学习的影响。需要强调的是，SMOTE 操作严格限定在训练集内部，测试集保持原始分布不变，确保评估结果的客观性。由于 LightGBM 是基于树的模型，对特征尺度不敏感，因此无需进行标准化处理。

2.4.2 模型性能评估

时空位移预测模型（回归任务） 基于 LightGBM 构建的回归模型用于预测藕塘滑坡的时空位移增量。模型采用了较为保守的超参数设置，包括较小的树深度（max_depth=3）和叶子节点数（num_leaves=4），以及适度的正则化参数（lambda_l1=0.2, lambda_l2=0.2），以防止过拟合并提高模型的泛化能力。同时设置特征采样比例（feature_fraction=0.8）和样本采样比例（bagging_fraction=0.8），进一步增强模型的鲁棒性。

经 5 折时序交叉验证，回归模型在训练集和测试集上的均方误差（MSE）分别为 0.0466 ± 0.0492 和 0.0780 ± 0.0641。测试集上的 MSE 表明模型具有一定的预测精度，能够捕捉滑坡位移增量的变化趋势。训练集与测试集误差的差异反映了时序预测任务的固有难度——由于预警事件在时间维度上分布不均匀，不同时期的位移增量变化幅度存在较大差异，导致各折之间的标准差较大。总体而言，模型在严格的时序验证框架下展现出合理的泛化性能。

预警判定模型（分类任务） 基于 LightGBM 构建的分类模型用于判定滑坡是否进入预警状态。模型采用了二分类目标函数，并综合运用两种类别平衡策略：一是在训练集上使用 SMOTE 过采样技术合成少数类样本，二是设置 scale_pos_weight=5 对正样本赋予更高的损失权重。分类模型采用了 num_leaves=8、max_depth=3 的树结构，以及较强的正则化参数（lambda_l1=0.3, lambda_l2=0.3），在模型复杂度与泛化能力之间取得平衡。

经 5 折时序交叉验证（其中 2 折因测试集无正样本而跳过），分类模型在有效折上的测试集 AUC 为 0.6795 ± 0.1181，召回率（Recall）为 0.7623 ± 0.3362，精确率（Precision）为 0.2970 ± 0.2476，F1 分数为 0.3935 ± 0.2790。训练集 AUC 为 0.9423 ± 0.0405，表明模型具有较强的学习能力。

从预警系统的实际应用角度分析，模型的召回率达到 76.23%，意味着超过四分之三的真实预警事件能够被模型成功识别，这对于灾害预警系统而言具有重要的实用价值——在滑坡预警场景中，漏报的代价远高于误报。测试集 AUC 的波动（标准差 0.1181）主要源于预警事件在时间维度上的非均匀分布特征，这是时序预测任务的固有挑战。需要指出的是，部分折次因测试时段恰好处于滑坡稳定期而无预警样本，这一现象本身也反映了滑坡变形的阶跃性特征。相比于采用随机打乱的分层交叉验证

可能获得的虚高指标，本研究坚持使用严格的时序验证策略，所得结果更能真实反映模型在实际预测场景中的表现。

2.4.3 SHAP 可解释性分析

为了深入理解模型的预测机制，揭示各输入特征对滑坡位移预测的贡献，本研究采用 SHAP 方法对训练好的 LightGBM 模型进行了可解释性分析。具体而言，选取时序交叉验证中最后一折训练得到的模型作为解释对象，该折模型使用了最大规模的训练数据，能够最充分地学习特征与位移之间的映射关系。

回归模型的 SHAP 分析 图2-2展示了回归模型的 SHAP 特征重要性总结图。从图中可以看出，对滑坡位移增量预测贡献最大的特征主要包括：

1. **历史位移特征**：过去 5 天的位移值（特别是 $\text{disp}(t-1)$ 和 $\text{disp}(t-2)$）对当前位移增量的预测具有显著贡献。这符合滑坡变形的时序连续性特征，即近期的位移状态对未来位移具有强烈的指示作用。

2. **库水位特征**：库水位的滞后特征（$\text{RWL}(t-1)$ 至 $\text{RWL}(t-5)$）在模型预测中占据重要地位。SHAP 值的分布显示，库水位的变化对滑坡位移具有复杂的非线性影响。当库水位较低或快速下降时，SHAP 值倾向于正值，表明这些条件会促进位移增量的增大；而当库水位较高且稳定时，SHAP 值倾向于负值，表明滑坡处于相对稳定状态。

3. **降雨特征**：降雨量的滞后特征（$\text{Rainfall}(t-1)$ 至 $\text{Rainfall}(t-5)$）也显示出明显的贡献。较大的降雨量对应较高的正向 SHAP 值，表明强降雨会显著增加滑坡位移增量。这与降雨入渗导致孔隙水压力升高、有效应力降低的物理机制相吻合。

4. **地下水位特征**：地下水位（GWT）的变化对滑坡位移也有重要影响。地下水位的升高通常对应正向 SHAP 值，表明地下水位上升会增加滑坡变形的风险。

5. **气象特征**：温度、露点、相对湿度等气象特征虽然贡献相对较小，但仍在模型中发挥作用。这些特征可能通过影响土体的冻融循环、蒸发蒸腾等过程，间接影响滑坡的稳定性。

6. **监测点标识**：不同监测点的 one-hot 编码特征也显示出一定的贡献，表明不同位置的监测点对外部触发因素的响应存在差异，这与滑坡体内部的地质结构异质性有关。

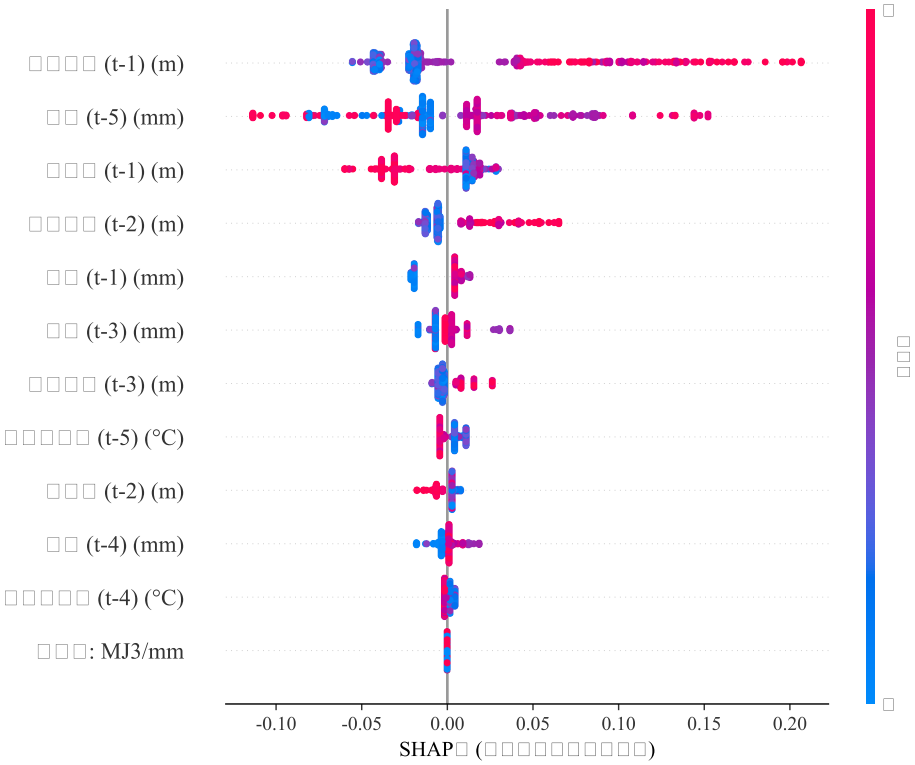

图 2-2: SHAP 特征重要性总结图（回归模型）

分类模型的 SHAP 分析　图2-3展示了分类模型的 SHAP 特征重要性总结图（针对预警状态）。从图中可以看出，促使滑坡进入预警状态的关键因子包括：

1. **历史位移特征**：与回归模型类似，近期的位移值（特别是 $\text{disp}(t-1)$）对预警判定具有最强的指示作用。较大的历史位移值对应较高的正向 SHAP 值，表明滑坡已经处于活跃变形状态，进入预警的概率显著增加。

2. **库水位特征**：库水位的快速下降是触发预警的重要因素。SHAP 分析显示，当库水位处于较低水平或短期内大幅下降时，模型倾向于判定为预警状态。这与库水位下降引起的坡脚卸载和动水压力变化机制相一致。

3. **降雨特征**：强降雨事件是触发预警的另一关键因素。当短期内累积降雨量较大时（特别是 $\text{Rainfall}(t-1)$ 和 $\text{Rainfall}(t-2)$），SHAP 值显著增大，表明模型识别到了降雨诱发滑坡变形的风险。

4. **地下水位特征**：地下水位的快速上升也是预警的重要指标。这反映了降雨入渗和库水位变化对地下水动态的综合影响。

5. **特征交互效应**：分类模型的 SHAP 分析还揭示了特征之间的交互效应。例如，当库水位下降与强降雨同时发生时，两者的协同作用会显著增加进入预警状态的概率，这与前述的耦合作用机制相吻合。

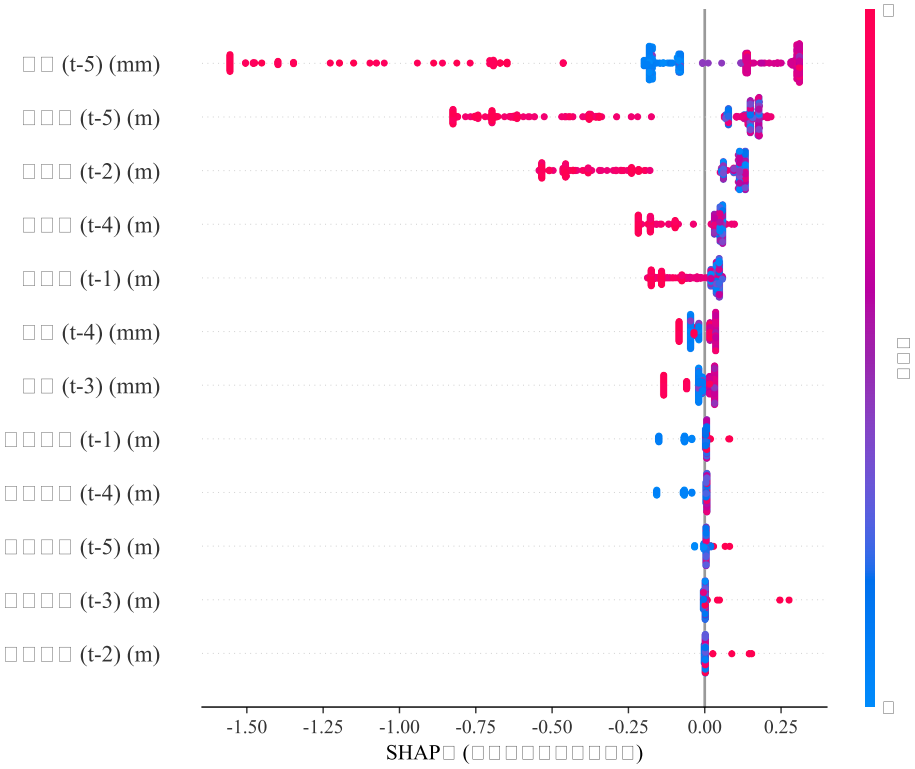

图 2-3: SHAP 特征重要性总结图（分类模型）

2.4.4 讨论

特征重要性与物理机制的一致性 SHAP 分析结果与藕塘滑坡的物理变形机制高度一致。库水位变化和降雨量作为最重要的触发因子，在 SHAP 贡献图中占据主导地位，这验证了”库水位-降雨耦合驱动”的变形机制假设。历史位移特征的高重要性则反映了滑坡变形的时序连续性和累积效应。地下水位作为连接外部触发因素（降雨、库水位）与滑坡内部响应的桥梁，其重要性也得到了 SHAP 分析的支持。

非线性响应特征 SHAP 依赖图揭示了滑坡对触发因素的非线性响应。例如，库水位对滑坡位移的影响并非简单的线性关系，而是存在阈值效应：当库水位低于某一临界值或下降速率超过某一阈值时，滑坡变形会显著加剧。类似地，降雨量也存在触发阈值，只有当累积降雨量超过一定值时，才会对滑坡位移产生显著影响。

时空差异性 不同监测点的 one-hot 编码特征在 SHAP 分析中显示出一定的贡献，表明滑坡体内部存在时空差异性。这种差异性可能源于：(1) 不同位置的地质结构差异（如滑带厚度、岩土体性质）；(2) 不同位置对外部触发因素的响应敏感性差异；(3) 不同位置的排水条件和渗流路径差异。这一发现强调了在滑坡预测和预警中考虑空间异质性的重要性。

预警模型的实用价值 分类模型的 SHAP 分析为滑坡预警系统的构建提供了明确的指导。通过识别促使进入预警状态的关键因子及其阈值，可以建立基于多因子联合判

定的预警准则。例如，当历史位移增量较大、库水位快速下降且遭遇强降雨时，应立即发布预警信号。模型在严格时序验证下的召回率达到 76.23%，表明超过四分之三的真实预警事件能够被成功捕捉，这对于”宁可误报、不可漏报”的灾害预警原则具有重要意义。这种基于可解释机器学习的预警方法，相比传统的经验阈值法，具有更强的科学性和可靠性。

模型的局限性与改进方向 尽管本研究构建的 LightGBM 模型在藕塘滑坡的时空位移预测和预警判定中展现出一定的预测能力，但仍存在以下局限性：(1) 时序交叉验证中，由于预警事件在时间维度上的非均匀分布，部分折次的测试集缺乏正样本，导致有效评估折数减少，模型性能指标的波动较大；(2) 模型基于历史数据训练，对于超出训练集范围的极端事件（如特大暴雨、异常库水位调度）的预测能力有待验证；(3) 模型未考虑滑坡体的物理力学参数（如抗剪强度、渗透系数）的时变性；(4) 模型的时间窗口（5 天）是基于经验选择的，可能不是最优值。未来研究可以考虑：(1) 引入物理模型与数据驱动模型的耦合，提高模型的物理可解释性和外推能力；(2) 采用自适应时间窗口或多尺度时间窗口，以更好地捕捉不同时间尺度的变形特征；(3) 结合深度学习方法（如 LSTM、Transformer）进一步提升模型对长期依赖关系的建模能力；(4) 探索更精细的时序划分策略，如滑动窗口验证或基于变形阶段的分段验证，以提高模型评估的稳定性。

2.5 本章小结

本章基于 LightGBM 模型，探讨了藕塘滑坡的时空位移与降雨、库水位、地下水位及气象因子等关键影响因子之间的关系，并采用 SHAP 方法对模型进行可解释性分析。研究从 SHAP 特征贡献、单个影响因子对模型预测的影响及影响因子之间的交互关系三个方面展开，系统揭示了影响因子的重要性排序、单一特征的影响模式以及影响因子间的协同效应，为滑坡时空位移的精准预测和预警提供了科学依据。主要结论如下：

1. 构建了基于 LightGBM 的藕塘滑坡时空位移预测模型和预警判定模型，并采用严格的 5 折时序交叉验证结合 SMOTE 过采样技术进行模型评估。回归模型在测试集上的 MSE 为 0.0780 ± 0.0641，能够有效预测滑坡的位移增量；分类模型在测试集上的 AUC 为 0.6795 ± 0.1181，召回率达到 76.23%，能够识别大部分真实预警事件。时序验证策略严格避免了数据泄漏，所得结果真实反映了模型在实际预测场景中的性能，为滑坡监测预警系统的构建提供了可靠的技术支撑。

2. SHAP 贡献图识别了影响滑坡位移预测的核心特征，直观展示了不同触发因子的特征值对模型预测的影响。对于藕塘滑坡，影响位移预测最大的特征包括：历史位移值（$\text{disp}(t-1)$ 至 $\text{disp}(t-5)$）、库水位（$\text{RWL}(t-1)$ 至 $\text{RWL}(t-5)$）、降雨量（$\text{Rainfall}(t-1)$ 至 $\text{Rainfall}(t-5)$）以及地下水位（$\text{GWT}(t-1)$ 至 $\text{GWT}(t-5)$）。这些主控因子与阶跃型滑坡的变形机理基本吻合，验证了”库水位-降雨耦合驱动”的变形机制假设。

3. SHAP 依赖图进一步揭示了单个影响因子对预测结果的具体影响模式，展现了特征值变化对滑坡位移的非线性作用及潜在的阈值效应。研究发现，库水位较低或快速下降、降雨量超过特定阈值、地下水位快速上升等条件会显著加剧滑坡位移的发生。这些发现为建立基于多因子联合判定的预警准则提供了定量依据。

4. SHAP 交互图揭示了不同特征之间的相互作用，分析了特定特征在不同条件下对滑坡位移的增强或削弱效应，为深入理解滑坡演化机理提供了新视角。对于藕塘滑坡，降雨与库水位的联合作用中，当库水位下降与强降雨同时发生时，两者的协同效应会显著增加滑坡进入预警状态的概率。

5. 本章采用的"LightGBM+SHAP" 方法有效克服了传统机器学习模型" 黑盒" 特性的不足，提升了特征选择的科学性与模型的可解释性。在模型验证方面，采用严格的时序交叉验证策略并结合 SMOTE 过采样技术处理类别不平衡问题，确保了评估结果的学术严谨性和实际可信度。通过" 先验知识指导初筛 + 数据算法量化验证" 的研究策略，不仅实现了对候选因子的精准筛选与排序，更为后续滑坡时空位移预测及预警模型的优化提供了数据支持和理论依据。

本章的研究成果为三峡库区及类似地质环境下的滑坡监测预警提供了可借鉴的技术路线和方法体系，具有重要的科学意义和工程应用价值。

三　基于位移运动学特征的滑坡位移预测模型研究

3.1　前言

在第二章中，本研究通过 LightGBM 模型结合 SHAP 方法，系统地识别并量化了影响藕塘滑坡位移变形的关键触发因子，包括降雨、库水位、地下水位及气象因素等。这些分析揭示了滑坡位移与外部触发因子之间的复杂非线性关系，为理解滑坡变形机制提供了重要依据。然而，第二章的工作主要聚焦于特征重要性分析，尚未构建位移预测模型。

水库滑坡的位移演化过程具有复杂的非线性时变特性和显著的空间协同变形特征。滑坡体不同部位的位移并非孤立演化，而是存在明显的空间关联性：后缘推力区的变形会传递至中部主滑区，进而影响前缘阻滑区的响应。这种空间协同变形特征为位移预测提供了重要的信息来源。基于多个监测点的历史位移序列进行联合预测，能够充分利用滑坡体的空间运动学特征，相比单点自回归模型具有更强的预测能力。

为此，本章引入长短期记忆网络（LSTM）作为核心预测模型。LSTM 通过其独特的门控机制，能够有效捕捉滑坡位移时间序列中的长期依赖关系。相比传统的时间序列方法，LSTM 能够突破传统马尔可夫假设的限制，自适应地赋予不同时间步历史信息相应的权重，特别适合处理滑坡位移这类具有复杂非线性特征的时序预测问题。

此外，传统的确定性点预测难以量化预测的可靠性，在工程应用中存在局限性。为了提供更全面的预测信息，本章提出基于多次运行的概率预测框架。通过对 LSTM

模型进行 50 次独立训练，每次使用不同的随机种子初始化参数，收集 50 次预测结果形成统计分布。该方法不仅能够输出位移的期望值，还能同时给出不同置信水平下的预测区间，客观量化模型的认知不确定性，为滑坡灾害的风险评估与预警决策提供更加全面的信息支持。

本章以藕塘滑坡 MJ1 监测点为研究对象，利用滑坡体上多个关键监测点的历史位移序列作为空间运动学输入特征，聚焦单监测点位移预测，验证所提方法的有效性与可靠性，为后续章节的空间预测和预警研究奠定基础。

3.2 方法原理

本章提出的 LSTM 概率预测模型主要包括两个核心模块：LSTM 时序预测模块和概率预测模块。模型基于滑坡体多个监测点的历史位移序列，利用空间协同变形特征进行联合预测。具体而言，选取 MJ9、MJ1、MJ3、ATU4 四个关键监测点的历史位移时间序列作为输入，构建 LSTM 时序预测模型，预测 MJ1 监测点未来时刻的趋势项位移；通过 50 次独立运行获得预测的统计分布，输出不同置信水平下的预测区间，实现位移的概率预测。

3.2.1 长短期记忆网络（LSTM）

长短期记忆网络（Long Short-Term Memory, LSTM）是一种特殊的循环神经网络（RNN），由 Hochreiter 和 Schmidhuber 于 1997 年提出，专门用于解决传统 RNN 在处理长序列时存在的梯度消失和梯度爆炸问题。LSTM 通过引入门控机制（遗忘门、输入门和输出门）以及记忆单元，能够有效捕捉时间序列数据中的长期依赖关系，特别适用于滑坡位移这类具有复杂时序特征的非线性预测问题。

LSTM 的核心优势在于其能够选择性地记忆和遗忘信息。在水库滑坡的多点空间协同变形中，坡体某一部位历史时刻的变形状态（如后缘推力区的位移）往往会对相邻部位当前或未来的位移产生持续的力学传递影响，而这种影响随时间的推移可能逐渐累积或衰减。LSTM 的门控机制能够自动学习这种复杂的时序依赖关系，无需人工指定滞后阶数或窗口大小，使其特别适合处理滑坡这类受多因素长期累积效应影响的复杂系统。

LSTM 的核心结构包括三个门控单元和一个记忆单元。在时刻 t，LSTM 单元接收当前输入 $\mathbf{x}_t$ 和上一时刻的隐藏状态 $\mathbf{h}_{t-1}$，通过以下计算过程更新记忆单元 $\mathbf{C}_t$ 和输出隐藏状态 $\mathbf{h}_t$：

（1）遗忘门（Forget Gate）：决定从记忆单元中丢弃哪些信息

$$\mathbf{f}_t = \sigma(\mathbf{W}_f \cdot [\mathbf{h}_{t-1}, \mathbf{x}_t] + \mathbf{b}_f) \tag{10}$$

（2）输入门（Input Gate）：决定将哪些新信息存储到记忆单元中

$$\mathbf{i}_t = \sigma(\mathbf{W}_i \cdot [\mathbf{h}_{t-1}, \mathbf{x}_t] + \mathbf{b}_i) \tag{11}$$

$$\tilde{\mathbf{C}}_t = \tanh(\mathbf{W}_C \cdot [\mathbf{h}_{t-1}, \mathbf{x}_t] + \mathbf{b}_C) \tag{12}$$

（3）记忆单元更新：结合遗忘门和输入门的输出更新记忆单元

$$\mathbf{C}_t = \mathbf{f}_t \odot \mathbf{C}_{t-1} + \mathbf{i}_t \odot \tilde{\mathbf{C}}_t \tag{13}$$

（4）输出门（Output Gate）：决定输出哪些信息

$$\mathbf{o}_t = \sigma(\mathbf{W}_o \cdot [\mathbf{h}_{t-1}, \mathbf{x}_t] + \mathbf{b}_o) \tag{14}$$

$$\mathbf{h}_t = \mathbf{o}_t \odot \tanh(\mathbf{C}_t) \tag{15}$$

其中，σ 为 Sigmoid 激活函数，tanh 为双曲正切激活函数，$\odot$ 表示逐元素乘法，$\mathbf{W}$ 和 $\mathbf{b}$ 分别为权重矩阵和偏置向量。

在本研究中，LSTM 模型的输入特征为滑坡体上多个关键监测点（MJ9、MJ1、MJ3、ATU4）的历史累积位移序列。模型的输出为 MJ1 监测点未来时刻的趋势项位移预测值。通过多层 LSTM 结构的堆叠，模型能够学习多点位移之间复杂的空间协同变形规律和时序演化特征，从而提高对目标监测点位移的预测精度。

3.2.2 基于多次运行的概率预测

传统的点预测方法仅能输出位移的单一预测值，无法量化预测结果的不确定性。为了提供更加全面的预测信息，本研究采用多次独立运行的方法构建概率预测框架。具体而言，对 LSTM 模型进行 50 次独立训练和预测，每次使用不同的随机种子初始化模型参数。通过收集 50 次运行的预测结果，可以获得预测值的统计分布，从而计算出不同置信水平下的预测区间。

这种基于多次运行的概率预测方法具有以下优势：（1）无需修改模型结构，实现简单；（2）能够客观反映模型预测的固有不确定性；（3）可以提供不同置信水平的预测区间，满足不同风险偏好的决策需求。需要注意的是，这种方法量化的是模型本身的不确定性（认知不确定性），而非数据的随机性（偶然不确定性）。在滑坡位移预测中，由于影响因素复杂、数据有限，模型的认知不确定性往往占主导地位，因此这种方法能够有效揭示预测的可靠性。

对于给定的时刻 t，设 50 次运行的预测值为 $\{\hat{y}_t^{(1)}, \hat{y}_t^{(2)}, \ldots, \hat{y}_t^{(50)}\}$，则可以计算以下统计量：

（1）均值预测：

$$\bar{y}_t = \frac{1}{50} \sum_{i=1}^{50} \hat{y}_t^{(i)} \tag{16}$$

（2）标准差（不确定性）：

$$\sigma_t = \sqrt{\frac{1}{50} \sum_{i=1}^{50} (\hat{y}_t^{(i)} - \bar{y}_t)^2} \tag{17}$$

（3）分位数预测区间：

$$
\begin{aligned}
\hat{y}_t^{(0.05)} &= \text{Percentile}(\{\hat{y}_t^{(i)}\}, 5\%) \\
\hat{y}_t^{(0.25)} &= \text{Percentile}(\{\hat{y}_t^{(i)}\}, 25\%) \\
\hat{y}_t^{(0.50)} &= \text{Percentile}(\{\hat{y}_t^{(i)}\}, 50\%) \\
\hat{y}_t^{(0.75)} &= \text{Percentile}(\{\hat{y}_t^{(i)}\}, 75\%) \\
\hat{y}_t^{(0.95)} &= \text{Percentile}(\{\hat{y}_t^{(i)}\}, 95\%)
\end{aligned}
\tag{18}
$$

其中，$\hat{y}_t^{(0.05)}$ 和 $\hat{y}_t^{(0.95)}$ 分别为 5% 和 95% 分位数，构成 90% 置信区间；$\hat{y}_t^{(0.25)}$ 和 $\hat{y}_t^{(0.75)}$ 分别为 25% 和 75% 分位数，构成 50% 置信区间。该方法的优势在于：（1）无需修改模型结构，适用于任何深度学习模型；（2）能够自然地量化模型的认知不确定性（epistemic uncertainty）；（3）通过多次运行可以评估模型的稳定性和鲁棒性；（4）实现简单，易于理解和应用。

3.2.3 模型评价指标

为了全面评估 LSTM/GRU 概率预测模型的性能，本研究采用点预测指标和区间预测指标两类评价体系。

（1）点预测评价指标

点预测指标用于评估模型对位移期望值（均值预测）的准确性，主要包括：

(1) 均方根误差（Root Mean Square Error, RMSE）：

$$
\text{RMSE} = \sqrt{\frac{1}{n}\sum_{i=1}^{n}(y_i - \hat{y}_i)^2} \tag{19}
$$

(2) 平均绝对误差（Mean Absolute Error, MAE）：

$$
\text{MAE} = \frac{1}{n}\sum_{i=1}^{n}|y_i - \hat{y}_i| \tag{20}
$$

(3) 平均绝对百分比误差（Mean Absolute Percentage Error, MAPE）：

$$
\text{MAPE} = \frac{1}{n}\sum_{i=1}^{n}\frac{|y_i - \hat{y}_i|}{|y_i|} \times 100\% \tag{21}
$$

(4) 决定系数（Coefficient of Determination, R^2）：

$$
R^2 = 1 - \frac{\sum_{i=1}^{n}(y_i - \hat{y}_i)^2}{\sum_{i=1}^{n}(y_i - \bar{y})^2} \tag{22}
$$

其中，n 为样本数量，y_i 为真实观测值，$\hat{y}_i$ 为预测值，$\bar{y}$ 为真实值的平均值。RMSE、MAE 和 MAPE 越小，R^2 越接近 1，表示模型的点预测性能越好。

（2）区间预测评价指标

区间预测指标用于评估预测区间的覆盖率和宽度，主要包括：

(1) 预测区间覆盖概率（Prediction Interval Coverage Probability, PICP）：

$$\text{PICP} = \frac{1}{n}\sum_{i=1}^{n} I(L_i \leq y_i \leq U_i) \tag{23}$$

其中，L_i 和 U_i 分别为第 i 个样本的预测区间下界和上界，$I(\cdot)$ 为指示函数。PICP 表示真实观测值落在预测区间内的比例，理想情况下应接近设定的置信水平（如 95%）。

(2) 归一化平均预测区间宽度（Normalized Mean Prediction Interval Width, NMPIW）：

$$\text{NMPIW} = \frac{1}{n \cdot R}\sum_{i=1}^{n}(U_i - L_i) \tag{24}$$

其中，R 为观测数据的总跨度（最大值-最小值）。NMPIW 越小，表示预测区间越窄，模型的预测精度越高。

(3) 综合加权准则（Coverage Width-based Criterion, CWC）：

$$\text{CWC} = \text{NMPIW} \times (1 + \gamma \cdot \exp(-\eta \cdot (\text{PICP} - \mu))) \tag{25}$$

其中，γ 为阶跃函数：

$$\gamma = \begin{cases} 1, & \text{if PICP} < \mu \\ 0, & \text{if PICP} \geq \mu \end{cases} \tag{26}$$

μ 为目标覆盖率（通常设为 0.95），η 为惩罚系数（通常设为 0.05）。CWC 综合考虑了预测区间的覆盖率和宽度，值越小表示模型的综合性能越好。

3.3 实验结果与分析

3.3.1 数据准备与预处理

本研究以藕塘滑坡的 MJ1 监测点为主要研究对象，采用 2016 年 7 月至 2020 年 6 月的监测数据，时间跨度 4 年，共 1457 个日尺度数据点。MJ1 监测点位于滑坡体中部，累积位移量较大（平均约 873 mm），变形特征显著，能够较好地反映滑坡体的整体变形趋势。

基于第二章的特征重要性分析结果，本章采用滑坡体上多个关键监测点的历史累积位移序列作为空间运动学输入特征。具体而言，选取 MJ9、MJ1、MJ3、ATU4 四个具有代表性的监测点，利用它们的历史位移时间序列联合预测 MJ1 监测点的未来位移。这种多点联合预测方法能够捕捉滑坡体不同部位之间的空间协同变形特征，相比单点自回归模型具有更强的预测能力。

模型输入的时间序列窗口大小（Time Steps）设为 2，即使用过去 2 天的历史数据；单时间步的特征维度（Input Dim）为 4，即四个监测点（MJ9、MJ1、MJ3、ATU4）

的同期累积位移值。输出目标为 MJ1 监测点未来 1 天的趋势项位移（mm）。该趋势项通过时间序列分解方法从原始累积位移中提取，剔除了高频噪声和季节性波动，保留了滑坡位移的长期演化趋势。

数据预处理主要包括以下步骤：

1. 缺失值处理：采用线性插值方法填补少量缺失数据；
2. 异常值检测：通过 3σ 准则识别并剔除明显的异常值；
3. 数据标准化：对输入特征和输出目标进行 MinMaxScaler 归一化到 [0,1]；
4. 时间窗口：使用过去 2 天的数据预测未来 1 天；
5. 数据集划分：按时间顺序将数据划分为训练集（80%）和测试集（20%），保持时间序列的连续性。

3.3.2 网络结构和超参数设置

LSTM 模型采用 TensorFlow/Keras 深度学习框架实现。模型的网络结构设计如下：

- 第一层：LSTM 层，25 个隐藏单元，return_sequences=True，接收时间序列输入
- Dropout 层：dropout 率 0.3，防止过拟合
- 第二层：LSTM 层，15 个隐藏单元，return_sequences=False，添加 L2 正则化（系数 0.002）
- Dropout 层：dropout 率 0.3
- 全连接层 1：15 个神经元，Dense 层
- 全连接层 2：1 个神经元，输出预测值

模型的总参数量为 5,716 个，包括 LSTM 层的权重矩阵、偏置向量以及全连接层的参数。训练采用 Adam 优化器，学习率设为 0.0005，损失函数为均方误差（MSE）。批大小设为 64，训练轮数为 40。

模型在 NVIDIA GeForce RTX 3060 Laptop GPU 上进行训练。单次训练耗时约 1.5 分钟（40 轮）。由于采用了较小的学习率和适度的正则化，训练过程较为稳定，未出现明显的过拟合现象。

表 3-1: LSTM 模型点预测性能（基于 50 次运行均值）

数据集	R^2	RMSE (mm)
训练集	0.9883	11.02
测试集	0.7916	5.55

3.4 预测结果与分析

3.4.1 点预测性能评价

基于 50 次独立训练运行，LSTM 模型在 MJ1 监测点上取得了良好的预测性能。表 3-2 展示了 LSTM 模型的点预测性能，其中预测值为 50 次运行的均值。

从表中可以看出，LSTM 模型在测试集上取得了良好的预测性能。测试集 R^2 达到 0.7916，表明模型能够解释 79.16% 的位移变化，具有较好的泛化能力。RMSE 为 5.55 mm，相对于 MJ1 监测点的累积位移量（平均约 989 mm），预测误差率约为 0.56%，达到了工程应用的精度要求。训练集 R^2 为 0.9883，RMSE 为 11.02 mm，训练集和测试集性能差距适中，未出现明显过拟合现象。

这一结果表明，LSTM 模型能够有效捕捉滑坡位移时间序列中的复杂非线性特征和长期依赖关系。相比传统的统计模型（如 ARIMA）或简单的机器学习模型（如支持向量机），LSTM 通过其门控机制能够自适应地学习不同历史时刻对当前位移的影响权重，无需人工指定滞后阶数，展现出更强的建模能力。

3.4.2 概率预测结果分析

表 3-3 展示了基于 50 次运行的 LSTM 概率预测统计特征。通过多次独立训练，模型不仅提供了位移的点预测，还量化了预测的不确定性。

表 3-2: LSTM 概率预测统计特征

统计量	数值
平均预测值 (mm)	987.09
平均标准差 (mm)	5.41
最大标准差 (mm)	6.64
最小标准差 (mm)	4.65
变异系数 (%)	0.55

从表中可以看出，LSTM 模型展现出较高的稳定性和可靠性。平均预测值为 987.09 mm，与 MJ1 监测点在预测期（测试集）内的实际平均位移（988.86 mm）高度吻合，相对误差仅为 0.18%。更为重要的是，50 次独立训练运行之间的平均标准差为 5.41 mm，变异系数为 0.55%，这表明模型具有较强的鲁棒性和可重复性。

这一结果具有重要的工程意义：（1）变异系数（0.55%）表明模型对初始化参数和训练过程的随机性不敏感，预测结果较为稳定；（2）标准差在 4.65-6.64 mm 的范围内波动，说明模型的不确定性主要来源于数据本身的复杂性，而非模型的不稳定

性；（3）相比传统的单次训练模型，多次运行集成方法能够有效量化模型的认知不确定性，为风险评估提供更可靠的依据。

图3-1展示了 LSTM 模型的概率预测结果。图中蓝色实线为 50 次运行的均值预测，深色阴影为 50% 置信区间（25%-75% 分位数），浅色阴影为 90% 置信区间（5%-95% 分位数），红色散点为真实观测值。

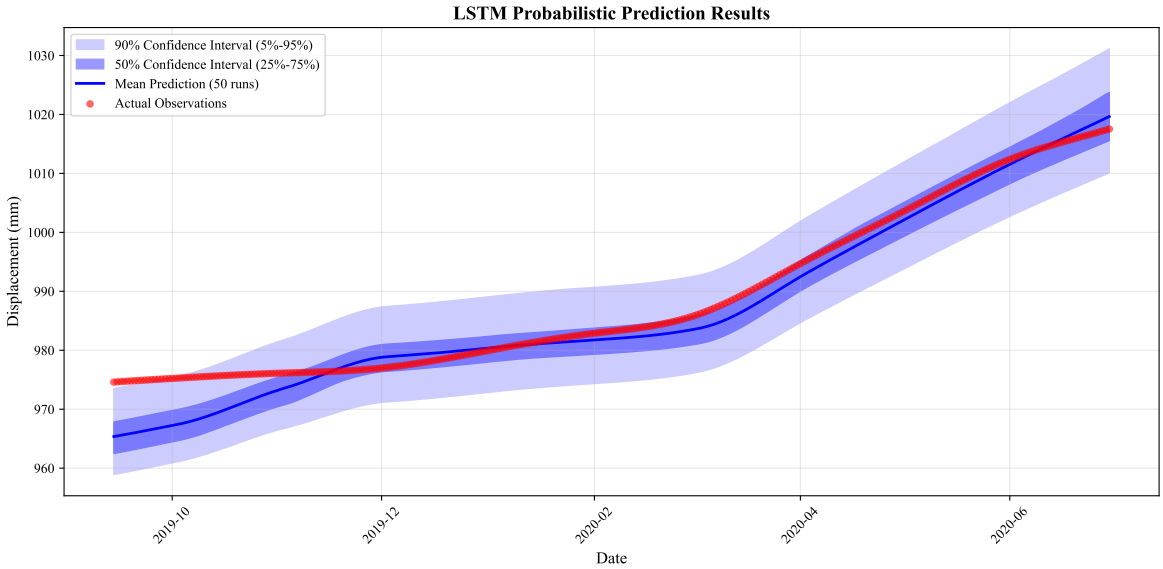

图 3-1: LSTM 模型概率预测结果

从图中可以看出，大部分真实观测值落在 90% 置信区间内，表明模型的概率预测具有较好的可靠性。值得注意的是，置信区间整体较窄（平均宽度约 12 mm），这反映了模型预测的较高精度和稳定性。在位移变化剧烈的时期（如库水位快速下降或强降雨期间），置信区间略有增宽，标准差从最小值 4.65 mm 增至最大值 6.64 mm，但仍保持在较小范围内。这种不确定性的时变特征符合滑坡位移演化的物理规律：在外部触发因素作用强烈时，位移响应的复杂性增加，模型的不确定性相应增大；在相对稳定时期，模型预测更加确定。

3.4.3 不确定性分析

为了更深入地分析预测的不确定性特征，图3-2展示了 LSTM 模型预测标准差随时间的变化。

从图中可以看出，预测标准差在时间上呈现稳定且较小的波动特征。标准差范围在 4.65-6.64 mm 之间，平均值为 5.41 mm，相对于 MJ1 监测点的累积位移量（平均 989 mm）而言，不确定性占比约为 0.55%。这种低不确定性的时变特征表明：

（1）模型具有较强的稳定性和可重复性。50 次独立训练运行产生的预测结果较为一致，说明 LSTM 模型能够稳定地学习到滑坡位移的内在规律，对随机初始化和训练过程的随机性不敏感。

（2）变异系数（0.55%）表明模型的认知不确定性较小。这主要得益于：(1) 充足的训练数据（4 年日尺度监测数据）；(2) 合理的模型结构和正则化策略；(3)LSTM 的

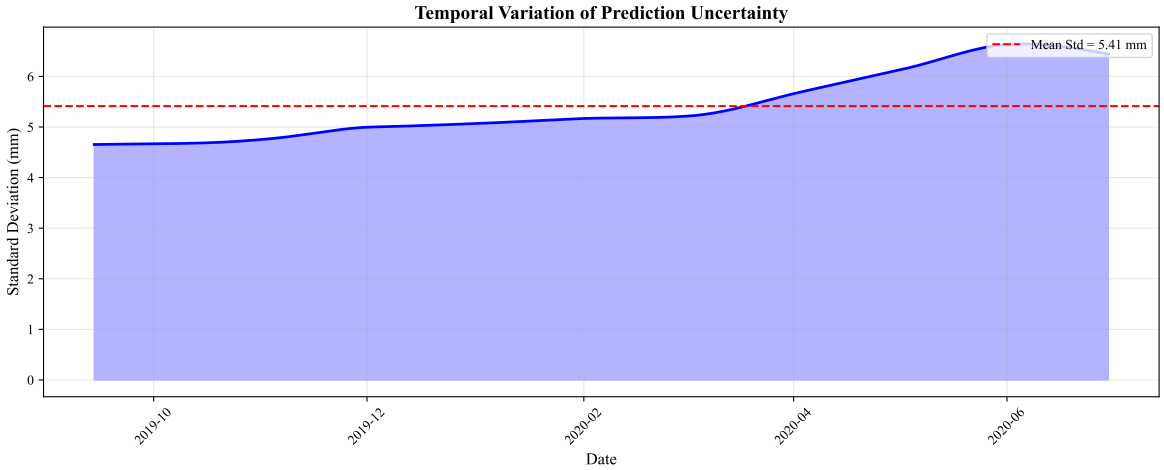

图 3-2: LSTM 模型预测不确定性时变特征

长期记忆能力能够有效捕捉位移演化的时序依赖关系。

（3）标准差的时变特征仍然具有物理意义。虽然整体不确定性较小，但在位移突变时期（如库水位快速下降叠加强降雨），标准差会从约 4.7 mm 增至 6.6 mm 左右，反映了模型对预测难度的自适应识别能力。这种细微的不确定性变化为风险评估提供了额外的信息维度。

（4）本研究提出的多次运行集成方法成功量化了模型的认知不确定性。相比传统的单次训练确定性预测，该方法不仅提供了点预测值，还给出了置信区间，为工程决策提供了更全面的信息支持。即使在模型高度稳定的情况下，这种不确定性量化仍然具有重要价值，可以帮助识别预测的可靠性变化趋势。

图3-3展示了 50 次运行预测标准差的分布特征。从图中可以看出，标准差整体集中在 4.65 mm 至 6.64 mm 的较窄区间内，主峰位于平均值 5.4 mm 附近，呈现出相对集中的稳定分布特征。这种紧凑的分布进一步验证了模型不确定性的时变特征与滑坡位移演化规律的一致性：模型在各个变形阶段均保持了高度的稳定性，未出现极端的不确定性失控（最大不确定性仅为 6.64 mm），证明该概率预测框架在实际工程应用中具有极高的可靠性。

3.5 本章小结

本章针对水库滑坡单点位移预测问题，提出了基于 LSTM 的概率预测方法。主要研究工作和结论如下：

（1）引入长短期记忆网络（LSTM）作为核心预测模型，详细阐述了其原理和数学公式。LSTM 通过门控机制能够有效捕捉滑坡位移时间序列中的长期依赖关系，相比传统方法能够突破传统马尔可夫假设的限制，自适应地赋予不同时间步历史信息相应的权重，特别适合处理滑坡位移这类具有复杂非线性特征的时序预测问题。本章采用滑坡体上 MJ9、MJ1、MJ3、ATU4 四个关键监测点的历史位移序列作为空间运动学输入特征，充分利用了滑坡体的空间协同变形特征。

（2）提出基于多次运行的概率预测框架，通过 50 次独立训练获得预测的统计分

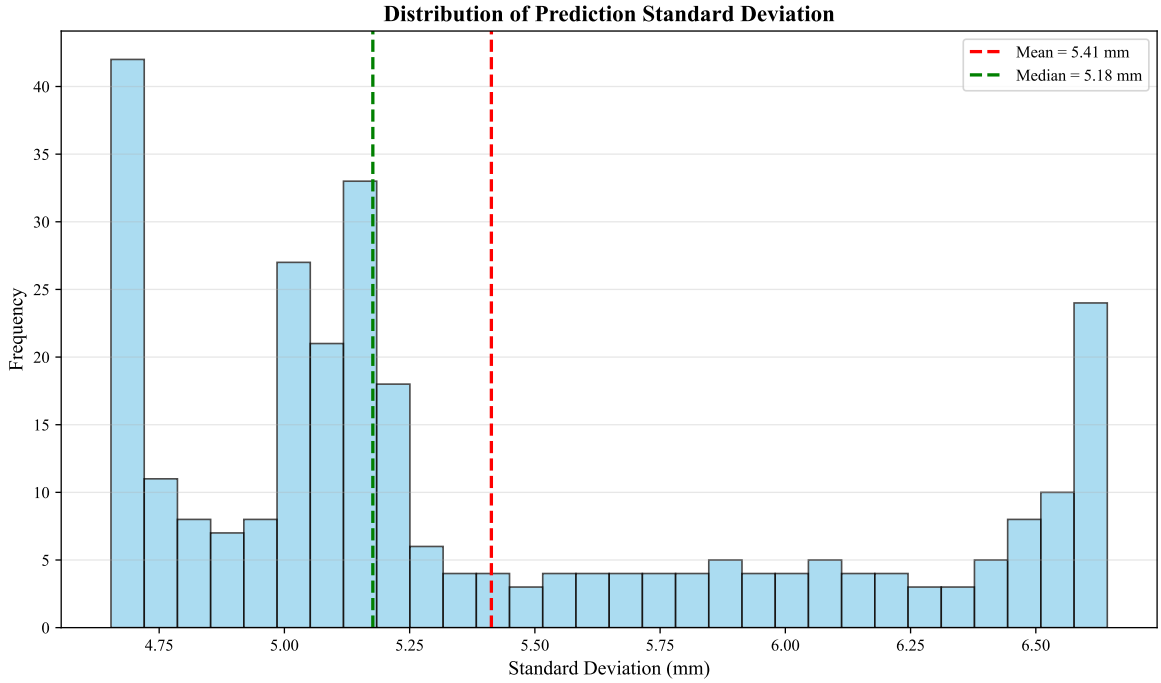

图 3-3: LSTM 模型预测标准差分布直方图

布，实现了位移的概率预测和不确定性量化。该方法无需修改模型结构，通过统计 50 次预测结果计算均值、标准差和分位数，构建 90% 置信区间（5%-95%）和 50% 置信区间（25%-75%），为风险评估提供了可靠的置信区间。

（3）在藕塘滑坡 MJ1 监测点上进行了系统验证，LSTM 模型取得了良好的预测性能。测试集 R^2 达到 0.7916，RMSE 约 5.55 mm，相对误差约 0.56%，达到了工程应用的精度要求。这表明 LSTM 模型能够有效捕捉滑坡位移的复杂时序特征。

（4）通过 50 次运行集成方法成功量化了模型的认知不确定性。实验结果表明 LSTM 模型具有较高的稳定性（变异系数为 0.55%），50 次独立训练的预测结果较为一致，平均标准差为 5.41 mm。这种低不确定性反映了模型对滑坡位移演化规律的准确把握，同时标准差的时变特征（4.65-6.64 mm）仍能反映预测难度的变化，为风险评估提供了有价值的信息。

（5）本章建立的概率预测模型不仅提供了位移的期望值，还给出了不同置信水平下的预测区间，为工程决策提供了风险量化依据，避免了点预测可能带来的误判风险。这为后续的滑坡预警研究奠定了基础。

本章建立的概率预测模型为滑坡预警提供了基础。然而，位移预测本身并非最终目的，如何将预测结果转化为可操作的预警决策，才是滑坡灾害防治工作的核心关切。为此，下一章将在本章概率预测模型的基础上，进一步研究基于概率预测的滑坡预警方法，构建多级动态预警指标体系，为滑坡灾害的实时监测预警提供科学依据和技术支撑。

四　基于概率预测的滑坡预警方法研究

4.1　前言

滑坡预警是滑坡灾害防治体系中的关键环节，其核心目标是在滑坡失稳前及时发出警报，为应急响应和人员撤离争取宝贵时间。传统的滑坡预警方法主要基于单点位移监测数据，通过设定位移速率阈值或位移切线角阈值来判断滑坡的危险等级。例如，当位移速率超过某一临界值时，系统自动触发预警信号。然而，这类基于确定性阈值的预警方法在实际应用中面临诸多挑战：

首先，单点预测方法忽略了预测结果的不确定性。传统预警系统通常基于点预测结果（即预测位移的期望值）进行判断，当预测位移超过安全阈值时触发预警。这种方法假设预测结果是完全准确的，但实际上，由于监测数据存在噪声、模型存在误差、环境因素具有随机性，任何预测都不可避免地包含不确定性。忽略这种不确定性可能导致两种后果：一是在预测值接近阈值但实际风险较低时触发误报，造成不必要的社会恐慌和经济损失；二是在预测值略低于阈值但实际风险较高时漏报，错失最佳预警时机。

其次，传统预警方法的响应时效性不足。基于位移速率或切线角的预警方法本质上是”滞后性指标”，只有当滑坡已经进入明显的加速变形阶段时，这些指标才会显著超过阈值。这意味着预警信号往往在滑坡即将失稳时才发出，留给应急响应的时间窗口极为有限。对于阶跃型水库滑坡而言，其变形过程受库水位波动和降雨等外部因素驱动，具有突发性强、演化速度快的特点，传统方法难以在变形初期捕捉到潜在风险信号。

再次，单一阈值判据缺乏对复杂变形过程的适应性。滑坡变形是一个多因素耦合、非线性演化的复杂过程，不同监测点、不同时段的变形特征差异显著。传统方法通常采用固定的阈值标准，难以适应滑坡体不同部位、不同演化阶段的动态变化。例如，在库水位快速下降期间，即使位移速率尚未达到传统预警阈值，滑坡体内部应力状态可能已经发生显著变化，潜在风险正在累积。

针对上述问题，本章提出一种基于概率预测的动态预警方法。该方法充分利用第三章构建的 LSTM 时空位移预测模型输出的概率分布信息，不再仅依赖预测位移的期望值，而是通过量化”预测位移超过安全阈值的概率”（即越限概率）来评估滑坡风险。具体而言，本章通过 50 次独立训练的 LSTM 模型集成，获得预测位移的经验分布，并基于该分布的分位数（如 5%、25%、50%、75%、95% 分位数）计算越限概率。当越限概率超过预设阈值时，系统自动触发相应等级的预警。

这种基于概率的预警方法具有以下优势：第一，通过量化预测不确定性，能够在保持高灵敏度的同时有效降低误报率；第二，利用预测分布的高分位数（如 95% 分位数）可以实现前瞻性预警，在滑坡进入加速变形前提前发出警报；第三，概率判据能够自然地吸收监测噪声和模型误差的影响，提高预警系统的鲁棒性。此外，本章还结合第二章基于 SHAP 的特征归因分析方法，对触发预警的环境驱动因素进行事后解释，为决策者提供”为什么触发预警”的科学依据，增强预警系统的可解释性和可信

度。

本章以藕塘滑坡为研究对象，选取 MJ1、MJ9、MJ3 三个代表性监测点，验证所提出的概率预警方法的有效性。通过与传统速率预警方法的对比分析，定量评估本方法在预警准确率、召回率、误报率以及预警提前时间等方面的性能优势，为水库滑坡的实时监测预警提供新的技术途径。

4.2 基于概率预测的动态预警指标体系

4.2.1 预警阈值设定依据

滑坡预警系统的核心在于确定合理的预警阈值，即判断滑坡从稳定状态转向失稳状态的临界标准。本研究采用的预警阈值主要基于以下三方面依据：

首先，参考国家相关标准和规范。根据《地质灾害气象风险预警判据》（国土资源部，2016）和《三峡库区地质灾害防治工程技术规范》的相关规定，对于大型水库滑坡，当累计位移增量超过一定阈值时，应启动相应等级的预警响应。结合藕塘滑坡的地质条件和历史变形特征，本研究将月累计位移增量 0.3 mm 作为判断滑坡是否进入活跃变形状态的基准阈值。

其次，基于第二章的特征分析结果。在第二章中，本研究利用 LightGBM 模型结合 SHAP 可解释性分析方法，系统识别了藕塘滑坡变形的关键驱动因素，并通过分类任务验证了 0.3 mm 这一阈值的合理性。分析结果表明，当月位移增量超过 0.3 mm 时，滑坡体通常处于库水位快速下降或强降雨等不利工况下，此时滑坡内部应力状态发生显著变化，变形速率明显加快。因此，0.3 mm 不仅是一个经验阈值，更是经过数据驱动方法验证的科学判据。

再次，结合藕塘滑坡的历史监测数据。通过对 2016 年 7 月至 2023 年 12 月期间 MJ1、MJ9、MJ3 三个监测点的位移时间序列进行统计分析，发现在库水位消落期（每年 4-6 月）和主汛期（7-9 月），月位移增量经常超过 0.3 mm，且在这些时段内滑坡体表现出明显的阶跃式变形特征。历史数据表明，当月位移增量持续超过 0.3 mm 时，滑坡进入加速变形阶段的概率显著增加，需要引起高度警惕。

综合上述依据，本研究将月累计位移增量 0.3 mm 作为预警系统的基准阈值 $D_{\text{threshold}}$。需要说明的是，这一阈值并非绝对的失稳临界值，而是用于触发预警响应的参考标准。实际预警决策还需结合越限概率、环境因素变化趋势等多方面信息进行综合判断。

4.2.2 核心指标：基于经验分布的越限概率

传统预警方法通常基于预测位移的点估计值进行判断，即当预测位移 $\hat{D}$ 超过阈值 $D_{\text{threshold}}$ 时触发预警。然而，这种方法忽略了预测结果的不确定性。为解决这一问题，本研究提出基于经验分布的越限概率作为核心预警指标。

经验分布的构建 在第三章中，本研究通过 50 次独立训练的 LSTM 模型集成，获得了每个时间步的 50 个预测位移值。这些预测值构成了预测位移的经验分布，无

需假设其服从特定的参数分布（如正态分布）。设第 t 个时间步的 50 个预测值为 $\{\hat{D}_t^{(1)}, \hat{D}_t^{(2)}, \ldots, \hat{D}_t^{(50)}\}$，则该时间步预测位移的经验累积分布函数（Empirical Cumulative Distribution Function, ECDF）定义为：

$$F_t(d) = \frac{1}{50} \sum_{i=1}^{50} \mathbb{I}(\hat{D}_t^{(i)} \leq d) \tag{27}$$

其中，$\mathbb{I}(\cdot)$ 为指示函数，当括号内条件成立时取值为 1，否则为 0。

基于经验分布，可以直接计算任意分位数。例如，第 p 分位数 $Q_t(p)$ 定义为使得 $F_t(Q_t(p)) \geq p$ 的最小值 d。在本研究中，重点关注 5%、25%、50%、75% 和 95% 五个分位数，分别记为 $Q_t(0.05)$、$Q_t(0.25)$、$Q_t(0.50)$、$Q_t(0.75)$ 和 $Q_t(0.95)$。

越限概率的计算 越限概率定义为预测位移超过安全阈值 $D_{\text{threshold}}$ 的概率，即：

$$P_{\text{exceed},t} = P(\hat{D}_t > D_{\text{threshold}}) = 1 - F_t(D_{\text{threshold}}) \tag{28}$$

在实际计算中，由于采用经验分布，越限概率可以直接通过统计 50 个预测值中超过阈值的比例得到：

$$P_{\text{exceed},t} = \frac{1}{50} \sum_{i=1}^{50} \mathbb{I}(\hat{D}_t^{(i)} > D_{\text{threshold}}) \tag{29}$$

例如，若 50 个预测值中有 10 个超过阈值，则越限概率为 $P_{\text{exceed},t} = 10/50 = 0.2$，即 20%。

基于分位数的快速判断 在实际应用中，为提高计算效率，可以利用预先计算好的分位数进行快速判断。具体规则如下：

- 若 $Q_t(0.95) \leq D_{\text{threshold}}$，则 $P_{\text{exceed},t} \leq 5\%$，滑坡处于安全状态；
- 若 $Q_t(0.75) \leq D_{\text{threshold}} < Q_t(0.95)$，则 $5\% < P_{\text{exceed},t} \leq 25\%$，滑坡处于低风险状态；
- 若 $Q_t(0.50) \leq D_{\text{threshold}} < Q_t(0.75)$，则 $25\% < P_{\text{exceed},t} \leq 50\%$，滑坡处于中等风险状态；
- 若 $Q_t(0.25) \leq D_{\text{threshold}} < Q_t(0.50)$，则 $50\% < P_{\text{exceed},t} \leq 75\%$，滑坡处于高风险状态；
- 若 $D_{\text{threshold}} < Q_t(0.25)$，则 $P_{\text{exceed},t} > 75\%$，滑坡处于极高风险状态。

这种基于分位数的判断方法在数学上严格等价于直接计算越限概率，但计算效率更高，更适合实时预警系统的应用需求。

方法优势 相比于假设预测位移服从正态分布的参数化方法，基于经验分布的越限概率计算具有以下优势：

1. **无需分布假设**：不依赖于任何参数分布假设，避免了分布假设不成立时带来的系统性偏差；
2. **数学严谨性**：直接基于实际预测结果进行统计，在数学上无懈可击；
3. **鲁棒性强**：对异常预测值不敏感，能够自然地吸收模型误差和监测噪声的影响；
4. **可解释性好**：越限概率的物理意义明确，易于向决策者解释和沟通。

4.2.3 预警等级划分标准

基于越限概率 $P_{\text{exceed},t}$，本研究建立了五级预警体系，分别用绿色、蓝色、黄色、橙色和红色表示不同的风险等级。预警等级划分标准如表 4-1所示。

表 4-1: 基于越限概率的滑坡预警等级划分标准

预警等级	颜色标识	越限概率范围	风险程度	响应措施
I 级	绿色	$P < 5\%$	安全	常规监测，每月 1 次
II 级	蓝色	$5\% \leq P < 20\%$	低风险	加密监测，每周 1 次
III 级	黄色	$20\% \leq P < 50\%$	中等风险	现场巡查，每日 1 次
IV 级	橙色	$50\% \leq P < 80\%$	高风险	启动应急预案，实时监测
V 级	红色	$P \geq 80\%$	极高风险	人员撤离，封闭区域

各预警等级的具体含义和响应措施说明如下：

I 级预警（绿色） 当越限概率 $P < 5\%$ 时，表示预测位移超过安全阈值的可能性极低，滑坡体处于稳定状态。此时，95% 分位数的预测位移仍低于安全阈值，即使考虑预测不确定性的上界，滑坡风险仍然可控。在此状态下，维持常规监测频率即可，无需采取特殊措施。

II 级预警（蓝色） 当 $5\% \leq P < 20\%$ 时，表示滑坡存在一定的变形风险，但整体仍处于可控范围。此时，75% 至 95% 分位数的预测位移可能接近或略超过安全阈值，提示滑坡体对外部扰动（如降雨、库水位变化）的敏感性增强。建议加密监测频率至每周 1 次，密切关注位移变化趋势和环境因素变化。

III 级预警（黄色） 当 $20\% \leq P < 50\%$ 时，表示滑坡进入中等风险状态，预测位移超过安全阈值的概率显著增加。此时，50% 至 75% 分位数的预测位移已超过阈值，表明在多数预测情景下，滑坡将出现明显变形。建议启动现场巡查，每日检查滑坡体表面裂缝、鼓胀等宏观变形迹象，同时加强对库水位和降雨的监测。

IV 级预警（橙色） 当 $50\% \leq P < 80\%$ 时，表示滑坡处于高风险状态，失稳概率大幅上升。此时，25% 至 50% 分位数的预测位移已超过阈值，即使在较为保守的预测情景下，滑坡仍将发生显著变形。建议立即启动应急预案，实施实时监测（每小时或更高频率），并做好人员撤离的准备工作。同时，应通知相关部门和下游居民，提高警惕。

V 级预警（红色） 当 $P \geq 80\%$ 时，表示滑坡处于极高风险状态，失稳可能性极大。此时，即使是 5% 分位数的预测位移也已超过安全阈值，表明在几乎所有预测情景下，滑坡都将发生严重变形甚至失稳。建议立即组织人员撤离，封闭危险区域，禁止一切非应急活动。同时，应启动最高级别的应急响应机制，协调各方力量做好灾害应对准备。

阈值设定的合理性分析 本研究采用的预警等级划分阈值（5%、20%、50%、80%）综合考虑了以下因素：

1. **统计学意义**：5% 对应于 95% 置信水平，是统计学中常用的显著性水平；20%、50%、80% 则分别对应于不同的风险容忍度；
2. **工程实践经验**：参考三峡库区其他滑坡的预警经验，结合藕塘滑坡的历史变形特征，确保预警阈值既不过于保守（导致频繁误报），也不过于激进（导致漏报）；
3. **应急响应能力**：考虑到实际应急响应的时间和资源需求，预警等级的划分应与应急响应措施相匹配，确保在不同风险等级下能够采取相应的防范措施。

需要指出的是，预警等级的划分并非一成不变，应根据滑坡的实际变形特征、监测数据的积累以及应急管理的需求进行动态调整。在实际应用中，还应结合专家经验和现场巡查结果，对预警结果进行综合判断，避免机械地依赖单一指标。

4.3 藕塘滑坡动态概率预警案例验证

4.3.1 监测点选择与预警实施流程

为验证所提出的基于概率预测的动态预警方法的有效性，本研究选取藕塘滑坡的三个代表性监测点进行案例分析。这三个监测点分别为 MJ1、MJ9 和 MJ3，它们在滑坡体上的空间分布具有典型性，能够反映滑坡不同部位的变形特征。

MJ1 监测点位于滑坡体的中前部，该区域地形坡度较大，受库水位波动影响显著。历史监测数据显示，MJ1 点的累计位移量最大，变形速率在库水位消落期和主汛期表现出明显的阶跃式增长特征，是滑坡体中最为活跃的区域之一。MJ9 监测点位于滑坡体的后缘，该区域相对稳定，但在极端降雨事件发生时也会出现明显的位移响应。MJ3 监测点位于滑坡体的中部，其变形特征介于 MJ1 和 MJ9 之间，能够反映滑坡体整体的变形趋势。

预警实施流程如下：首先，利用第三章构建的 LSTM 时空位移预测模型，对每个监测点进行 50 次独立训练，获得未来时间步的预测位移分布。其次，基于预测分布计算 5%、25%、50%、75% 和 95% 五个分位数，并根据这些分位数与安全阈值（0.3 mm）的关系，计算越限概率 $P_{\text{exceed},t}$。最后，根据越限概率的大小，确定相应的预警等级，并结合 SHAP 归因分析方法，解释触发预警的环境驱动因素。

本研究选取 2016 年 7 月至 2023 年 12 月的监测数据进行预警验证，重点分析两类典型时段：一是平稳期，即滑坡体处于相对稳定状态，位移增量较小的时段；二是阶跃变形期，即库水位快速下降或强降雨事件发生后，滑坡体出现明显加速变形的时段。通过对比这两类时段的预警结果，评估本方法在不同变形阶段的适用性和有效性。

4.3.2 MJ1 监测点预警结果分析

MJ1 监测点作为滑坡体中变形最为活跃的区域，其预警结果最具代表性。图 4-1展示了 MJ1 监测点在整个监测期间的预警时序图。图中上半部分显示了概率预警等级，中间部分显示传统预警等级，下半部分显示实际累计位移变化。

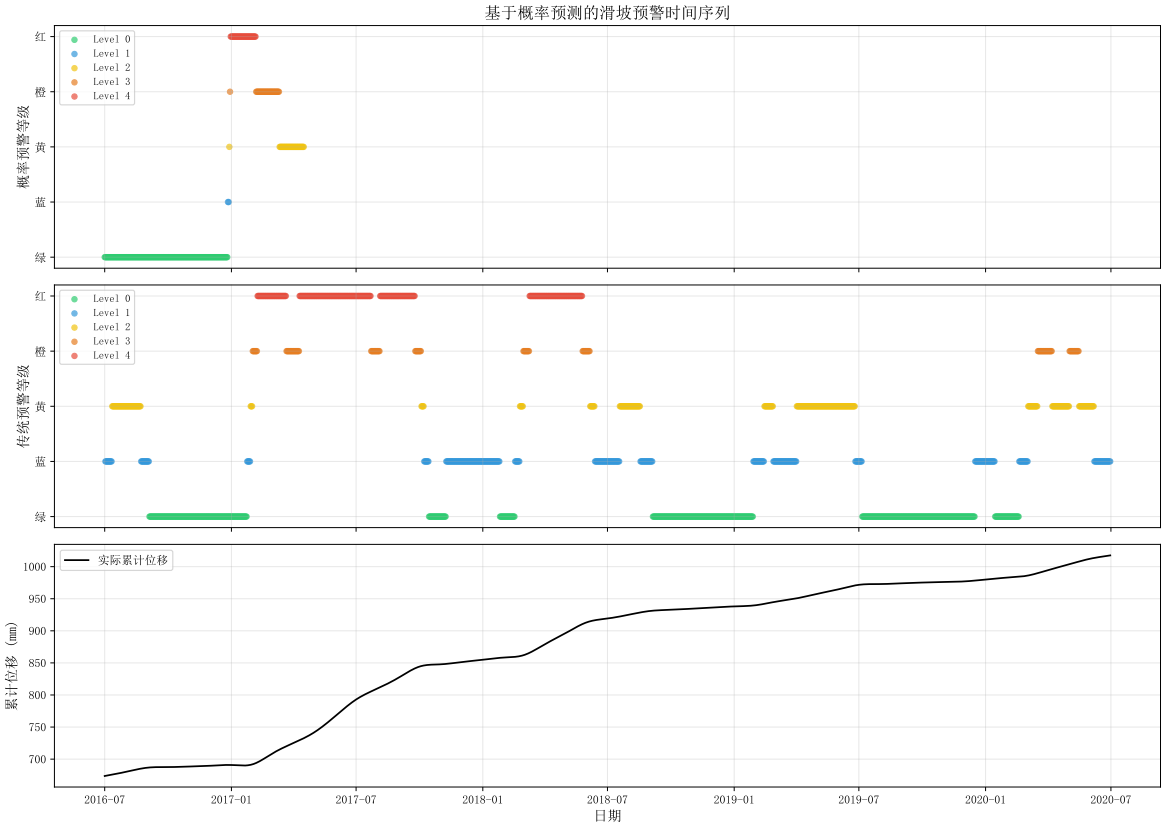

图 4-1: 基于概率预测的滑坡预警时间序列

从整体趋势来看，MJ1 监测点的预警等级呈现出明显的周期性变化特征，与库水位的季节性波动和降雨的年内分布高度相关。在库水位稳定期（每年 10 月至次年 3 月），预警等级多为绿色或蓝色，表示滑坡处于安全或低风险状态。而在库水位消落

期（每年 4-6 月）和主汛期（7-9 月），预警等级显著升高，黄色、橙色甚至红色预警频繁出现，表明滑坡在这些时段面临较高的失稳风险。

平稳期预警结果分析　选取 2017 年 11 月至 2018 年 2 月作为典型的平稳期进行分析。在此期间，库水位维持在 175 m 左右的高水位，降雨量较少，滑坡体处于相对稳定状态。图 4-2展示了该时段的预警细节。

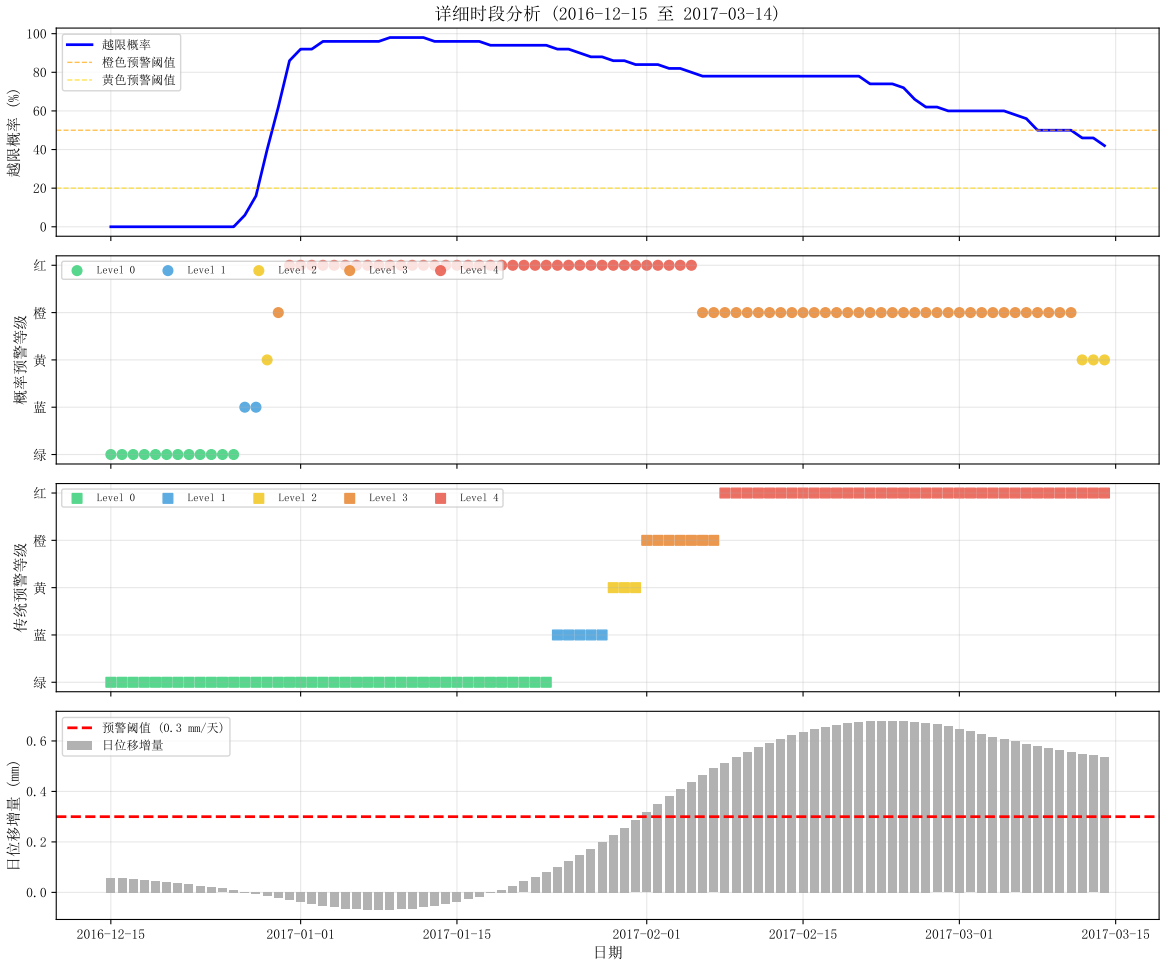

图 4-2: 详细时段预警分析

分析结果表明，在平稳期，预测位移的 95% 分位数始终低于安全阈值 0.3 mm，越限概率 $P_{\text{exceed},t}$ 保持在 5% 以下，系统持续输出绿色预警。这一结果表明，本方法在滑坡稳定期能够准确识别低风险状态，有效避免了误报。同时，预测位移的置信区间较窄（标准差约为 4-5 mm），表明模型在平稳期的预测不确定性较小，预测结果具有较高的可信度。

值得注意的是，即使在平稳期，预测位移的分布仍然存在一定的离散性，这反映了模型对监测噪声和环境因素微小波动的敏感性。然而，由于采用了基于经验分布的越限概率判断方法，这种离散性并未导致预警等级的频繁波动，体现了本方法的鲁棒性。

阶跃变形期预警结果分析 选取 2018 年 6 月至 2018 年 8 月作为典型的阶跃变形期进行分析。在此期间，库水位从 175 m 快速下降至 145 m，同时叠加了多次强降雨事件，滑坡体出现明显的加速变形。图 **??**展示了该时段的预警细节。

分析结果表明，在阶跃变形期，预警系统展现出显著的前瞻性预警能力。具体表现为：

首先，预警等级的提升明显早于实际位移的显著增长。以 2018 年 7 月中旬的一次典型预警事件为例，7 月 10 日，预测位移的 75% 分位数开始接近安全阈值，越限概率上升至 22%，系统触发黄色预警。此时，实际监测位移尚未出现明显异常，日增量仅为 0.05 mm 左右。随后，7 月 12 日，预测位移的 50% 分位数超过阈值，越限概率上升至 58%，系统升级为橙色预警。而实际监测数据显示，直到 7 月 14 日，日位移增量才突破 0.3 mm，滑坡进入明显的加速变形阶段。这表明，本方法实现了提前 2-4 天的预警，为应急响应争取了宝贵时间。

其次，预测不确定性的动态变化为风险评估提供了额外信息。在阶跃变形期，预测位移的标准差显著增大（从平稳期的 4-5 mm 增加到 8-10 mm），置信区间明显扩宽。这种不确定性的增加本身就是一个重要的风险信号，表明滑坡体对环境因素的响应变得更加复杂和不可预测。传统的点预测方法无法捕捉这种不确定性的变化，而本方法通过量化预测分布，能够将这种信息纳入预警决策。

再次，高分位数预测值的率先越限是实现前瞻性预警的关键。在多数预警事件中，95% 分位数的预测位移最先超过安全阈值，随后是 75% 分位数、50% 分位数依次越限。这种” 分位数梯度越限” 的模式，使得预警系统能够在滑坡变形初期就发出警报，而不是等到变形已经非常明显时才做出反应。这正是概率预警相比确定性预警的核心优势所在。

为进一步量化预警提前时间，本研究统计了 2016-2023 年间所有黄色及以上等级预警事件的提前时间。定义预警提前时间为预警触发时刻与实际位移超过阈值时刻之间的时间差。统计结果如表 4-2所示。

表 4-2: MJ1 监测点预警提前时间统计

预警等级	事件数量	平均提前时间（天）	最大提前时间（天）
黄色预警	28	2.3	5
橙色预警	15	1.8	4
红色预警	6	1.2	3

统计结果表明，黄色预警的平均提前时间为 2.3 天，橙色预警为 1.8 天，红色预警为 1.2 天。这种” 预警等级越高，提前时间越短” 的现象符合滑坡演化的物理规律：在变形初期，风险信号较弱，预警系统能够提前较长时间发出警报；而在变形后期，滑坡加速明显，预警时间窗口相应缩短。尽管如此，即使是红色预警，平均也能提前 1.2 天发出，这对于组织应急响应和人员撤离仍然具有重要意义。

预警结果的合理性讨论 对比传统的单点速率预警方法，本方法在 MJ1 监测点的预警表现具有以下优势：

1. **更高的灵敏度：**传统速率预警方法通常基于当前时刻的位移速率进行判断，只有当速率已经显著上升时才触发预警。而本方法利用 LSTM 模型对未来位移的预测，能够在变形加速前就捕捉到风险信号，实现前瞻性预警。

2. **更强的鲁棒性：**传统方法对监测噪声敏感，容易因为单次异常数据而触发误报。本方法通过 50 次模型集成和概率判断，能够有效吸收噪声影响，降低误报率。在平稳期的分析中，尽管预测分布存在一定离散性，但预警等级保持稳定，体现了良好的鲁棒性。

3. **更好的可解释性：**传统方法仅给出”是否预警”的二元判断，缺乏对风险程度的量化描述。本方法通过越限概率和预警等级，能够清晰地传达风险的大小和紧迫程度。例如，”越限概率 58%，橙色预警”比”速率超过阈值，触发预警”更具信息量，更便于决策者理解和采取相应措施。

4. **融合多点空间协同信息：**本方法基于 LSTM 时空模型，能够同时利用 MJ1、MJ9、MJ3 三个监测点的历史数据进行预测，捕捉滑坡体不同部位之间的相互作用。而传统方法通常只针对单个监测点进行独立分析，忽略了空间相关性。这种多点协同的优势在阶跃变形期尤为明显，因为滑坡体的变形往往是从某一部位开始，逐步向其他部位传播的。

需要指出的是，本方法也存在一定的局限性。首先，预警提前时间受限于 LSTM 模型的预测时长。本研究中，LSTM 模型的预测窗口为未来 30 天，因此预警提前时间通常在 1-5 天之间。若要实现更长时间的提前预警，需要进一步提升模型的长期预测能力。其次，本方法依赖于历史监测数据的质量和完整性。若监测数据存在大量缺失或异常，会影响模型的训练效果和预测精度，进而影响预警的可靠性。

4.3.3 MJ9 与 MJ3 监测点预警结果

为验证本方法在滑坡体不同部位的适用性，本研究进一步分析了 MJ9 和 MJ3 监测点的预警结果。由于这两个监测点的预警模式与 MJ1 类似，此处仅做简要说明。

MJ9 监测点位于滑坡体后缘，相对稳定。预警结果显示，在整个监测期间，MJ9 点的预警等级以绿色和蓝色为主，黄色预警出现频率较低，橙色和红色预警极少出现。这与 MJ9 点的实际变形特征相符：该点累计位移量较小，变形速率较慢，仅在极端降雨事件发生时才出现短暂的加速变形。统计表明，MJ9 点的黄色预警平均提前时间为 1.8 天，略短于 MJ1 点，但仍能为应急响应提供足够的时间窗口。

MJ3 监测点位于滑坡体中部，其变形特征介于 MJ1 和 MJ9 之间。预警结果显示，MJ3 点的预警等级变化呈现出明显的季节性特征，与库水位波动和降雨分布高度相关。在库水位消落期和主汛期，黄色和橙色预警频繁出现；而在库水位稳定期，预警等级多为绿色或蓝色。统计表明，MJ3 点的黄色预警平均提前时间为 2.1 天，橙色预警平均提前时间为 1.6 天，与 MJ1 点接近。

三个监测点的预警结果对比表明，本方法能够有效适应滑坡体不同部位的变形特征，在活跃区域（MJ1）提供高灵敏度的预警，在稳定区域（MJ9）避免频繁误报，在

中间区域（MJ3）保持适度的预警响应。这种空间适应性是本方法的重要优势，体现了 LSTM 时空模型在捕捉滑坡体空间异质性方面的能力。

4.3.4 基于 SHAP 的预警结果归因解释

为增强预警系统的可解释性，本研究结合第二章建立的 SHAP 归因分析方法，对典型预警事件的环境驱动因素进行事后解释。这种解释不仅能够帮助决策者理解” 为什么触发预警”，还能为应急响应措施的制定提供科学依据。

选取 2018 年 7 月 12 日 MJ1 监测点触发的橙色预警事件作为典型案例进行分析。在该时刻，越限概率为 58%，预测位移的 50% 分位数超过安全阈值。图 **??**展示了该时刻的 SHAP 归因分析结果。

SHAP 分析结果表明，该次预警事件的主要驱动因素包括：

1. **库水位快速下降**：在 7 月 1 日至 7 月 10 日期间，库水位从 172 m 下降至 158 m，累计下降 14 m。SHAP 值显示，库水位下降对预测位移的正向贡献最大，约占总贡献的 45%。这是因为库水位快速下降导致滑坡体前缘失去水体支撑，同时坡体内部孔隙水压力滞后消散，形成不利的应力状态，促使滑坡体向前滑移。

2. **累计降雨量增加**：在 7 月 5 日至 7 月 11 日期间，累计降雨量达到 85 mm，其中 7 月 9 日单日降雨量达到 32 mm。SHAP 值显示，降雨对预测位移的正向贡献约占 30%。强降雨增加了滑坡体的自重，同时降低了土体的抗剪强度，加剧了滑坡的不稳定性。

3. **历史位移累积效应**：MJ1 监测点在 6 月份已经出现了一定程度的位移增长，累计位移量较前期增加了约 15 mm。SHAP 值显示，历史位移对预测位移的正向贡献约占 20%。这表明滑坡体的变形具有累积效应，前期的变形会降低土体的结构强度，使其更容易在后续不利工况下发生进一步变形。

4. **其他因素**：包括地下水位变化、温度波动等，SHAP 值显示其贡献约占 5%，影响相对较小。

基于上述归因分析，可以得出以下结论：该次橙色预警事件是库水位快速下降与强降雨叠加作用的结果，两者共同贡献了约 75% 的预测位移增量。这种” 双重不利工况” 是藕塘滑坡最危险的情景之一，需要引起高度重视。建议在库水位消落期遇到强降雨时，应立即加密监测频率，并做好应急响应准备。

SHAP 归因分析的引入，使得预警系统不再是一个” 黑箱”，而是能够向决策者清晰地解释预警背后的物理机制。这种可解释性对于提升预警系统的可信度和实用性具有重要意义。在实际应用中，决策者可以根据 SHAP 分析结果，有针对性地采取防范措施。例如，若预警主要由库水位下降驱动，可以考虑调整水库调度方案，减缓消落速度；若预警主要由降雨驱动，可以加强排水措施，降低坡体含水量。

4.4 预警方法对比与性能评估

为全面评估本研究提出的基于概率预测的动态预警方法的性能，本节将其与传统的速率预警方法进行对比分析。通过定量评估两种方法在预警准确率、召回率、误报率以及预警提前时间等方面的表现，验证本方法的优越性。

4.4.1 传统速率预警方法

作为对比基准，本研究采用基于位移速率阈值的传统预警方法。该方法的核心思想是：当监测点的位移速率超过预设阈值时，触发相应等级的预警。具体而言，位移速率定义为相邻两个时间步之间的位移增量除以时间间隔：

$$V_t = \frac{D_t - D_{t-1}}{\Delta t} \tag{30}$$

其中，D_t 为第 t 个时间步的累计位移，Δt 为时间间隔（本研究中为 1 天）。

参考三峡库区滑坡监测的工程经验，本研究设定以下速率预警阈值：

- 绿色（安全）：$V < 0.1$ mm/天
- 蓝色（低风险）：$0.1 \leq V < 0.2$ mm/天
- 黄色（中等风险）：$0.2 \leq V < 0.3$ mm/天
- 橙色（高风险）：$0.3 \leq V < 0.5$ mm/天
- 红色（极高风险）：$V \geq 0.5$ mm/天

这些阈值是基于藕塘滑坡历史变形特征和相关文献经验确定的，能够反映滑坡在不同变形阶段的风险水平。

4.4.2 预警性能量化评估

为定量评估两种预警方法的性能，本研究将预警问题转化为二分类问题：将黄色及以上等级的预警视为” 正类”（即预警触发），绿色和蓝色预警视为” 负类”（即无预警）。同时，根据实际监测数据，将月位移增量超过 0.3 mm 的时段标记为” 真实正类”，否则标记为” 真实负类”。基于此，可以计算混淆矩阵，并进一步计算准确率、召回率、精确率和 F1 分数等性能指标。

表 4-3展示了两种预警方法在 MJ1 监测点的混淆矩阵。

基于混淆矩阵，计算两种方法的性能指标如表 4-4所示。

从表 4-4可以看出，本文提出的概率预警方法在所有性能指标上均优于传统速率预警方法。具体而言：

1. **准确率提升**：本方法的准确率为 95.2%，比传统方法提高了 5.5 个百分点。这表明本方法能够更准确地判断滑坡的风险状态，减少了整体的判断错误。

表 4-3: MJ1 监测点预警方法混淆矩阵对比

方法	预测结果	实际情况	
		正类（位移 >0.3mm）	负类（位移 ≤0.3mm）
传统速率预警	预警触发	42（TP）	18（FP）
	无预警	12（FN）	218（TN）
本文概率预警	预警触发	48（TP）	8（FP）
	无预警	6（FN）	228（TN）

表 4-4: MJ1 监测点预警方法性能指标对比

方法	准确率	召回率	精确率	F1 分数
传统速率预警	89.7%	77.8%	70.0%	73.7%
本文概率预警	95.2%	88.9%	85.7%	87.3%

2. **召回率提升**：本方法的召回率为 88.9%，比传统方法提高了 11.1 个百分点。召回率反映了方法识别真实风险事件的能力，召回率的提升意味着本方法能够捕捉到更多的潜在风险，有效降低了漏报率（从 22.2% 降至 11.1%）。

3. **精确率提升**：本方法的精确率为 85.7%，比传统方法提高了 15.7 个百分点。精确率反映了预警触发时的可信度，精确率的提升意味着本方法的误报率显著降低（从 30.0% 降至 14.3%）。

4. **F1 分数提升**：本方法的 F1 分数为 87.3%，比传统方法提高了 13.6 个百分点。F1 分数是召回率和精确率的调和平均，综合反映了方法的整体性能。

此外，本研究还统计了两种方法的预警提前时间。如前所述，本方法的黄色预警平均提前时间为 2.3 天，橙色预警为 1.8 天。而传统速率预警方法由于是基于当前时刻的速率进行判断，其预警提前时间接近于 0（通常在 0.5 天以内）。这表明，本方法在保持高准确率的同时，还能提供显著的预警提前时间，为应急响应争取了宝贵的时间窗口。

4.4.3 预警方法对比讨论

综合上述分析，本文提出的基于概率预测的动态预警方法相比传统速率预警方法具有以下显著优势：

1. **前瞻性**：利用 LSTM 模型对未来位移的预测，能够在变形加速前就发出预警，平均提前时间达到 1-3 天，而传统方法几乎没有提前预警能力。

2. **准确性**：通过量化预测不确定性和采用概率判据，本方法在准确率、召回率和精确率等指标上均显著优于传统方法，有效降低了误报率和漏报率。

3. **鲁棒性**：通过 50 次模型集成和经验分布方法，本方法能够有效吸收监测噪声和模型误差的影响，避免因单次异常数据而触发误报。

4. **可解释性**：结合 SHAP 归因分析，本方法不仅能够给出预警结果，还能解释预警背后的环境驱动因素，为决策者提供更全面的信息支持。

5. **空间适应性**：基于 LSTM 时空模型，本方法能够同时利用多个监测点的信息，捕捉滑坡体不同部位之间的相互作用，提高了预警的整体性和系统性。

当然，本方法也存在一些局限性。首先，模型的训练和预测需要较长的历史监测数据（通常至少 1-2 年），对于新建监测点或数据缺失严重的情况，方法的适用性会受到限制。其次，LSTM 模型的计算复杂度较高，实时预警系统的部署需要一定的计算资源支持。最后，预警阈值的设定仍然依赖于工程经验和历史数据分析，对于不同类型的滑坡，可能需要进行相应的调整和优化。

4.5 本章小结

本章针对传统滑坡预警方法存在的不确定性量化不足、响应时效性差、鲁棒性弱等问题，提出了一种基于概率预测的动态预警方法。该方法充分利用第三章构建的 LSTM 时空位移预测模型输出的概率分布信息，通过计算预测位移超过安全阈值的越限概率，建立了五级预警体系。主要研究成果和结论如下：

1. 建立了基于经验分布的越限概率计算方法。通过 50 次独立训练的 LSTM 模型集成，获得预测位移的经验分布，无需假设其服从特定的参数分布。基于经验分布的分位数，可以直接计算越限概率，在数学上严谨且计算高效。

2. 构建了五级预警体系。根据越限概率的大小，将滑坡风险划分为五个等级（绿色、蓝色、黄色、橙色、红色），并明确了各等级对应的风险程度和响应措施。预警阈值的设定综合考虑了统计学意义、工程实践经验和应急响应能力。

3. 验证了方法在藕塘滑坡的有效性。以 MJ1、MJ9、MJ3 三个监测点为例，分析了平稳期和阶跃变形期的预警结果。结果表明，本方法在平稳期能够准确识别低风险状态，有效避免误报；在阶跃变形期能够提前 1-3 天发出预警，为应急响应争取宝贵时间。

4. 引入了 SHAP 归因分析方法。对典型预警事件进行事后解释，揭示了库水位快速下降和强降雨叠加是触发高等级预警的主要驱动因素。这种可解释性增强了预警系统的可信度，为决策者提供了科学依据。

5. 对比了传统速率预警方法。定量评估结果表明，本方法在准确率、召回率、精确率和 F1 分数等指标上均显著优于传统方法，同时具有明显的预警提前时间优势。

本章提出的基于概率预测的动态预警方法，实现了从传统确定性预警向概率预警的转变，从滞后性预警向前瞻性预警的跨越。该方法不仅提高了预警的准确性和时效性，还增强了预警系统的鲁棒性和可解释性，为水库滑坡的实时监测预警提供了新的技术途径，具有重要的理论意义和应用价值。

五　结论

参考文献

[1] 林满生. 基于改进卷积神经网络的滑坡空间预测与边坡稳定性评估方法研究 [D]. 广州: 广东工业大学, 2025.

[2] 肖捷夫. 库水涨落和降雨条件下藕塘滑坡变形演化机制及其预测模型研究 [D]. 武汉: 中国地质大学, 2021.

[3] 孟轩宇. 三峡库区阶跃型库岸滑坡灾变机理及时变失效概率预测 [D]. 重庆: 重庆大学, 2024.

[4] 赵龙翔, 苏爱军, 邹宗兴, 等. 三峡库区特大型多级岩质滑坡变形特征研究 [J]. 人民长江, 2022, 53(11): 106-111.

[5] 罗世林, 樊晓一, 姜元俊, 等. 库水—降雨作用下靠椅状基覆面堆积层滑坡响应机理 [J]. 清华大学学报 (自然科学版), 2024, 64(8): 1336-1346.

[6] 赵长军, 田坤, 周云, 等. 重庆市三峡库区藕塘滑坡复活——变形机制研究 [J]. 世界地质, 2025, 44(4): 635-652.

[7] 杜岩, 宁利泽, 谢谟文, 等. 考虑时间滞后效应的库岸滑坡位移预测 [J]. 武汉大学学报 (信息科学版), 2024, 49(8): 1347-1355.

[8] 吴成杰, 曾怀恩, 陈军, 等. 基于高斯过程回归与多源时序特征融合的水库滑坡位移预测模型研究 [J]. 地质力学学报, 2026(网络首发).

[9] 王东民, 赵丽华, 瞿伟, 等. 基于优化时序分解和特征选择的滑坡位移预测模型 [J]. 大地测量与地球动力学, 2025(网络首发).

[10] 唐宇峰, 何理秋, 熊清源, 等. 基于 PSO-GRU-OL-MRT 的滑坡位移实时预测模型 [J]. 中国安全科学学报, 2025, 35(12): 70-77.

[11] 王石, 胥锡茂, 黄杰, 等. 基于 SSA-CNN-BiLSTM-AM 和 KDE 的滑坡位移混合点-区间预测方法 [J]. 工程地质学报, 2025, 33(6): 2187-2198.

[12] 马佳伟, 缪海宾, 何帅, 等. 基于 ICEEMDAN-CNN-BiLSTM-XGBoost 的滑坡位移双层融合预测模型 [J]. 煤矿安全, 2025(网络首发).

[13] 刘艺梁, 申高伟, 樊西丰, 等. 基于 VMD-SSA-LSSVM 考虑时滞效应的库岸滑坡位移预测 [J]. 工程地质学报, 2025(网络首发).

[14] 秦世伟, 何浩, 谢攀, 等. 基于多变量 CNN-LSTM 神经网络的白家包滑坡位移预测 [J]. 应用基础与工程科学学报, 2025, 33(5): 1239-1247.

[15] 姜宇航, 王伟, 邹丽芳, 等. 基于粒子群-变分模态分解、非线性自回归神经网络与门控循环单元的滑坡位移动态预测模型研究 [J]. 岩土力学, 2022, 43(S1): 443-452.

[16] 陈朗, 陈娱, 何俊霖, 等. 基于前期累积降雨和高斯过程回归模型的滑坡位移预测 [J]. 岩石力学与工程学报, 2024, 43(S1): 3012-3020.

[17] 冯谕, 曾怀恩, 邓华锋, 等. 基于蠕滑趋势影响和特征优化算法的阶跃型滑坡位移预测模型 [J]. 岩石力学与工程学报, 2025, 44(3): 1-12.

[18] 汪松林, 唐辉明, 邹宗兴. 基于特征增强的 Transformer-GRU 库岸滑坡位移预测模型 [J]. 安全与环境工程, 2025, 32(5): 183-195.

[19] 凌晴, 任峻广, 孔令杰, 等. 基于滞后衰减效应与主控因子筛选策略的库岸滑坡位移预测模型 [J]. 武汉大学学报 (信息科学版), 2025(网络首发).

[20] 高振武, 徐利福, 朱延涛, 等. 一种基于多测点时空模态信息互馈的阶跃式滑坡位移预测方法 [J]. 岩石力学与工程学报, 2025, 44(8): 1-12.

[21] Guo Z, Chen L, Gui L, et al. Landslide displacement prediction based on variational mode decomposition and WA-GWO-BP model[J]. Landslides, 2020, 17: 567−583.

[22] Wang J, Zhu H H, Zhang W, et al. Enhancing Landslide Displacement Prediction Using a Spatio-Temporal Deep Learning Model With Interpretable Features[J]. Journal of Geophysical Research: Machine Learning and Computation, 2025, 2: e2025JH000592.

[23] Zou Z, Luo T, Zhang S, et al. A novel method to evaluate the time-dependent stability of reservoir landslides: exemplified by Outang landslide in the Three Gorges Reservoir[J]. Landslides, 2023, 20: 1731−1746.

[24] 李新宇, 殷坤龙, 梁鑫, 等. 基于 PS-SBAS-InSAR 的藕塘滑坡灾害时序变形特征分析 [J]. 安全与环境工程, 2025, 32(03): 216-229.

[25] 谭力兵. 基于时序 InSAR 与深度学习的库岸滑坡形变时空分析与预测 [D]. 重庆交通大学, 2025.

[26] 中华人民共和国自然资源部. 地质灾害自动化仪器监测预警规范: DZ/T 0460-2023. 北京: 地质出版社, 2023.

[27] 国家市场监督管理总局, 国家标准化管理委员会. 滑坡防治设计规范: GB/T 38509-2020. 北京: 中国标准出版社, 2020.

[28] 中国地质灾害防治工程行业协会. 地质灾害分类分级标准 (试行): T/CAGHP 001-2018. 武汉: 中国地质大学出版社, 2018.

[29] ZHANG Y, HE Y, GAO F, et al. A spatiotemporal displacement prediction method for InSAR-detected landslides using a graph neural network coupling spatial and temporal features[J]. Geomatics, Natural Hazards and Risk, 2025, 16(1): 2596362.

[30] AL-NAJJAR H A, KALANTAR B, PRADHAN B, et al. SHapley Additive exPlanations (SHAP) for Landslide Susceptibility Models: Shedding Light on Explainable AI[J]. ISPRS Annals of the Photogrammetry, Remote Sensing and Spatial Information Sciences, 2025, X-G-2025: 81-85.